南京大学
NANJING UNIVERSITY

自然语言处理

规则方法

吴震

南京大学人工智能学院
南京大学自然语言处理研究组

2023年6月

引言

- **课程目标**
  - 了解自然语言处理的发展历程、研究任务/方向
    - 语言模型、文本分类、机器翻译、预训练模型等
  - 掌握自然语言处理的基本方法
    - 规则方法、隐马尔科夫模型、神经网络等
  - 建立利用自然语言处理知识解决现实问题的能力
    - 自动问答、对话系统等

引言：为什么需要规则方法？

- **Text2SQL**
  - 输入一句话，将这句话转换成SQL可执行的查询语句

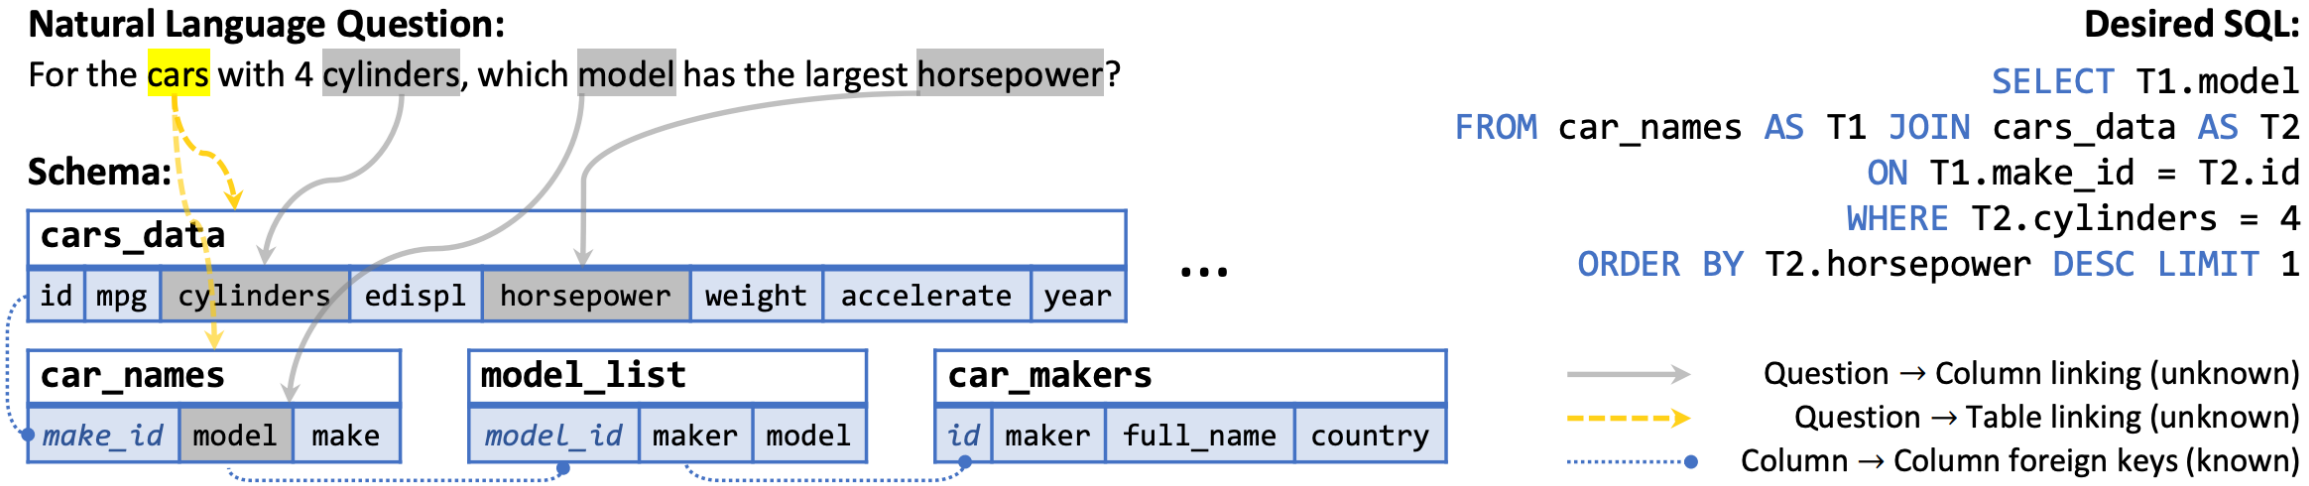

- 缺乏足够的标注数据
- 自然语言和SQL语言间复杂的对应关系

机器学习 → 自然语言处理

自然语言分类-基于形态结构

- 分析型语言
  - 没有或很少有词形变化
  - 词的语法功能由词序和虚词来表达
  - 汉语、藏语等
- 屈折型语言
  - 有词形变化（通过词缀）
  - 词的语法功能由词的形态变化来表达
  - 英语、德语、法语等

自然语言分类-基于形态结构

- 黏着型语言
  - 有词形变化和附加成分
  - 词的语法功能由词的形态变化和附加成分来表达
  - 日语、芬兰语等

以日本语"食べる"为例:

食べ る Tabe ru - "吃" (基本形、将来时)

食べ させ る Tabe sase ru - "吃" + 使役助动词 - 使/要求(某人)吃

食べ させ られ る Tabe sase rare ru - "吃" + 使役助动词 + 被动助动词 - 被(其他人)要求(我)吃

食べ させ られ ない Tabe sase rare nai - "吃" + 使役助动词 + 被动助动词+ 否定助动词 - 不被(其他人)要求(我)吃

食べ させ られ な かった Tabe sase rare na katta - "吃" + 使役助动词 + 被动助动词 + 否定助动词 + 过去助动词 - 曾不被(其他人)要求(我)吃

自然语言分类-基于“主动宾”位置

- SVO型（主-动-宾）
  - 英语、汉语等
- SOV型（主-宾-动）
  - 日语等
- VSO型（动-主-宾）
  - 古阿拉伯语等

对翻译的影响？

规则方法时代

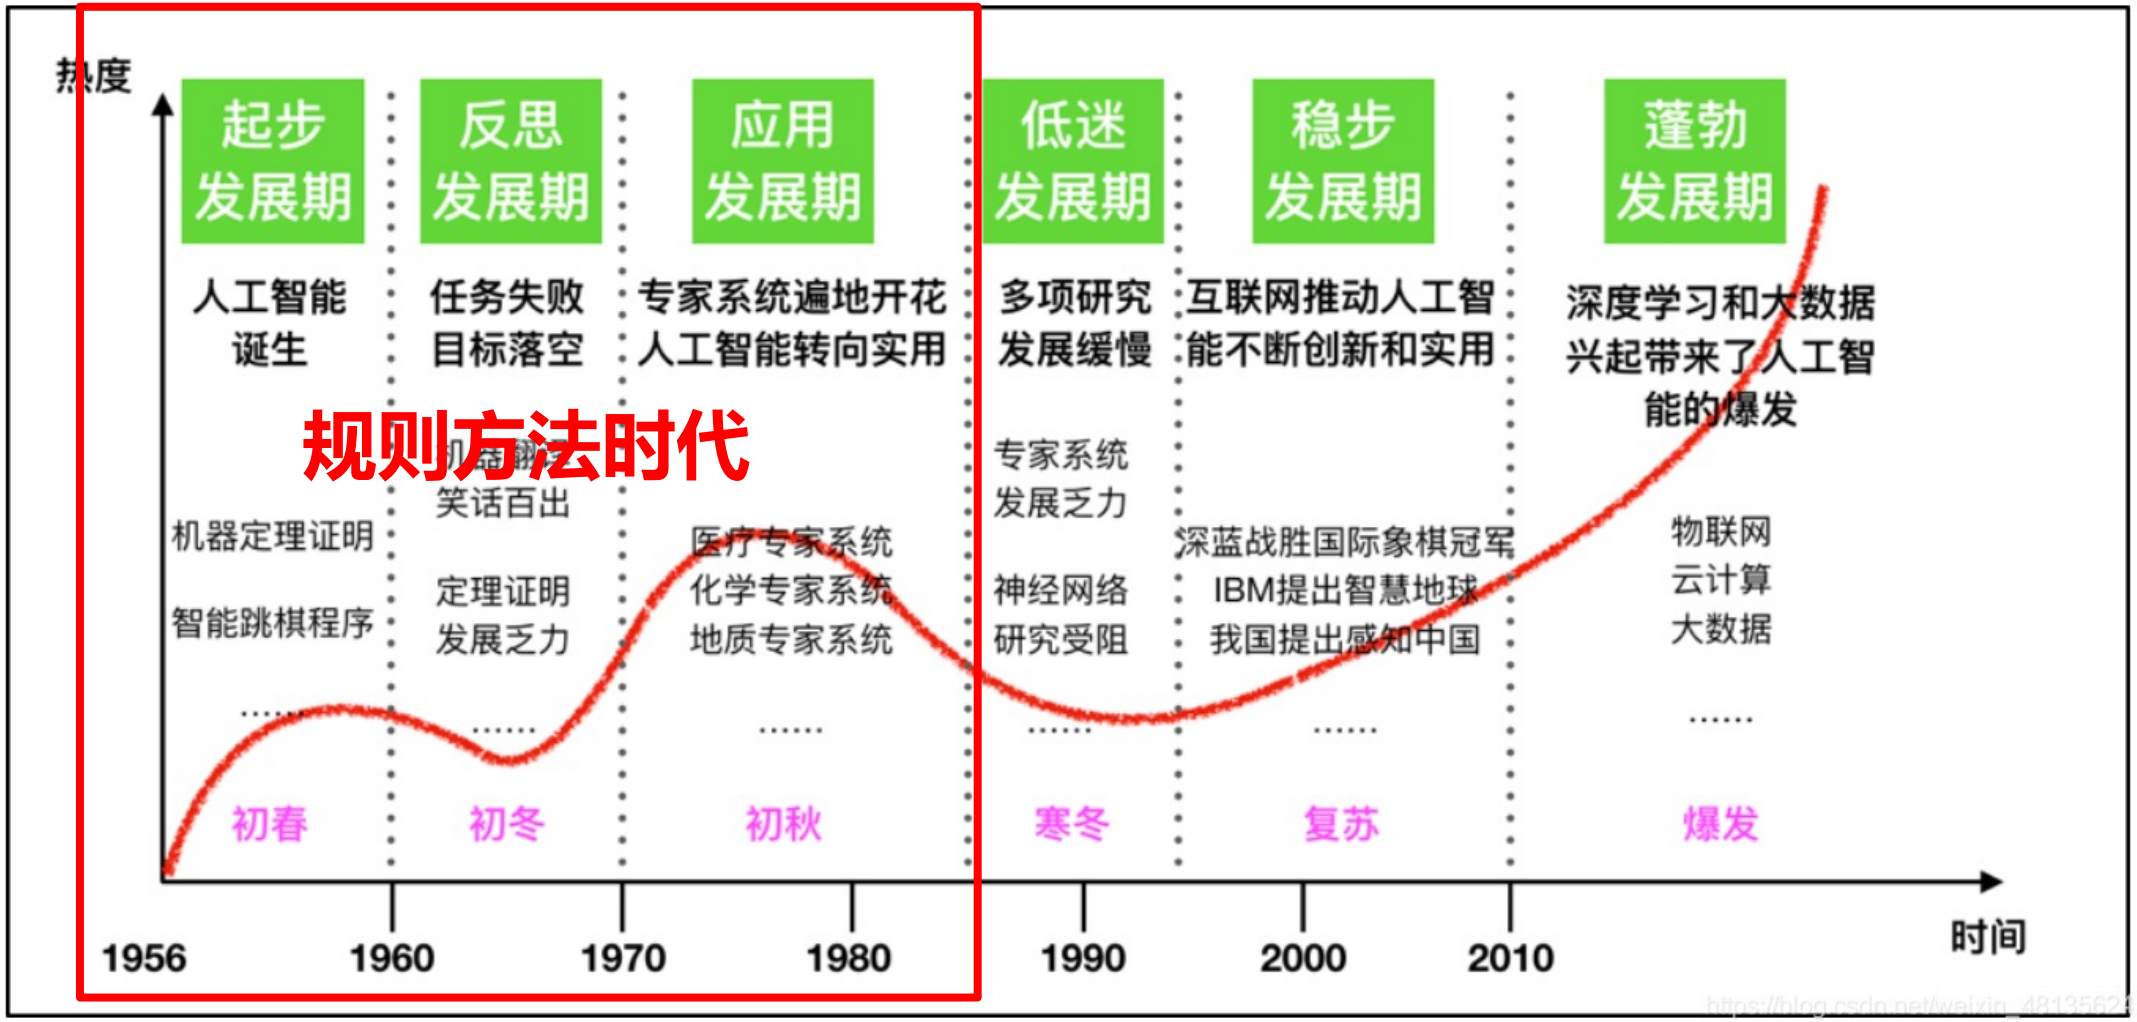
热度
起步发展期
反思发展期
应用发展期
低迷发展期
稳步发展期
蓬勃发展期
人工智能诞生
任务失败目标落空
专家系统遍地开花人工智能转向实用
多项研究发展缓慢
互联网推动人工智能不断创新和实用
深度学习和大数据兴起带来了人工智能的爆发
规则方法时代
机器翻译
笑话百出
机器定理证明
智能跳棋程序
定理证明发展乏力
医疗专家系统
化学专家系统
地质专家系统
专家系统发展乏力
神经网络研究受阻
深蓝战胜国际象棋冠军
IBM提出智慧地球
我国提出感知中国
物联网
云计算
大数据
初春
初冬
初秋
寒冬
复苏
爆发
1956
1960
1970
1980
1990
2000
2010
时间

规则方法

- 以**规则形式**表示语言知识
- 基于规则的知识表示和推理
- 强调人对语言知识的理性整理（知识工程）
- 受计算语言学理论指导
- 语言规则（数据）与程序分离，程序体现为规则语言的解释器！

规则方法

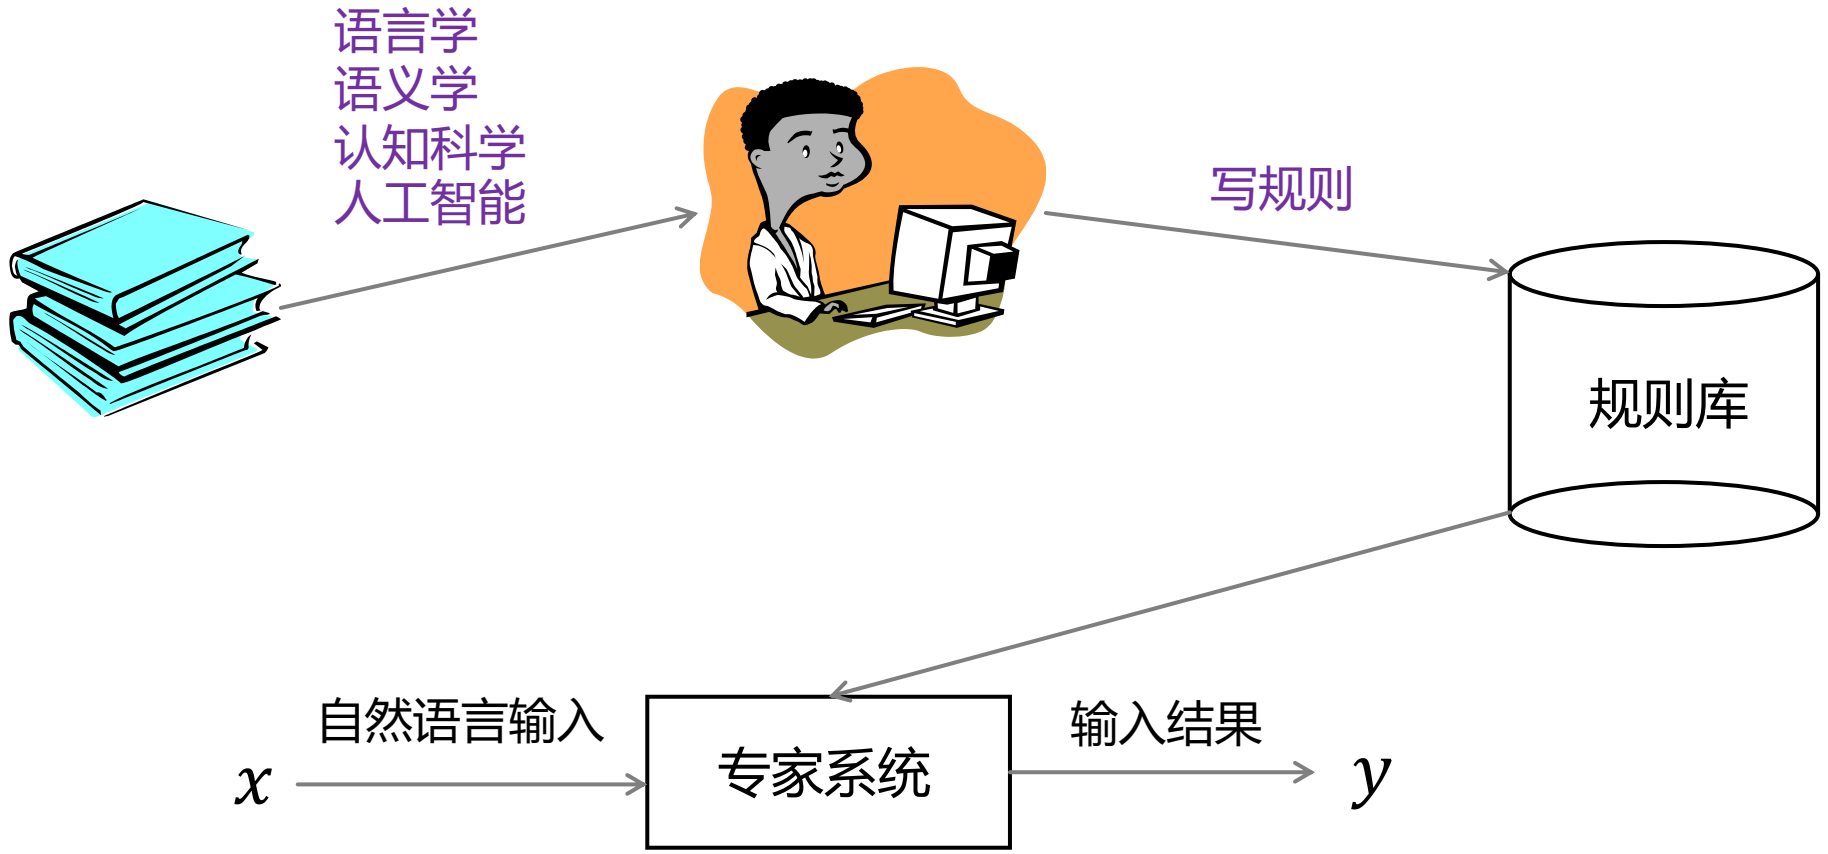

规则方法

- 词法分析
- 句法分析
- 语义分析
- ……

词法分析

- 形态还原（针对英语、德语、法语等）
  - 把句子中的词还原成它们的基本词形（原形）
- 分词（针对汉语、日语等）
  - 识别出句子中的词
- 词性标注
  - 为句子中的词标上预定义类别集合中的类
- 命名实体识别
  - 识别出句子中的人名、地名、机构名等

形态还原（英语）

南京大学 NANJING UNIVERSITY

- 把句子中的词还原成原形，作为词的其它信息的索引（词典、个性规则）
- 构词特点
  - 屈折变化：词尾和词形变化，词性不变。如：
    - study, studied, studied, studying
    - speak, spoke, spoken, speaking
  - 派生变化：加前缀和后缀，词性发生变化。如：
    - friend, friendly, friendship,...
  - 复合变化：多个单词以某种方式组合成一个词。
- 还原规则
  - 通用规则：变化有规律
  - 个性规则：变化无规律

形态还原（英语）

南京大学 NANJING UNIVERSITY

- 规则动词还原举例
  - *s -> * (SINGULAR3)
  - *es -> * (SINGULAR3)
  - *ies -> *y (SINGULAR3)
  - *ing -> * (VING)
  - *ing -> *e (VING)
  - *ying -> *ie (VING)
  - *??ing -> *? (VING)
  - *ed -> * (PAST)(VEN)
  - *ed -> *e (PAST)(VEN)
  - *ied -> *y (PAST)(VEN)
  - *??ed -> *? (PAST)(VEN)

形态还原（英语）

- 不规则动词还原举例
  - went -> go (PAST)
  - gone -> go (VEN)
  - sat -> sit (PAST) (VEN)

形态还原

- 基本算法（给定一段文本）
  1. 输入一个单词
  2. 如果原型词典里有该词，输出该词及其属性
  3. 如果有该词的还原规则，并且词典里有还原后的词，则输出还原后的词及其属性；否则，调用<未登录词模块>
  4. 如果输入中还有单词，转1；否则，结束。

中文分词

- 词是语言中最小的能独立运用的单位，也是语言信息处理的基本单位。
- 分词是指根据某个分词规范，把一个“字”串划分成“词”串。
- 分词规范
  - 由于单字词的存在，有时无法区分：
    - 词与语素：猪肉（鸭肉）、猪在奔跑、肉很香
    - 词与词组：黑布、黑板
  - 信息处理用现代汉语分词规范：GB-13715（1992）
  - 具体应用系统可根据各自的需求制定规范

中文分词-切分歧义

- 交集型歧义
  - ABC切分成AB/C或A/BC
  - 如：“和平等”
    - “独立/自主/和/平等/独立/的/原则”
    - “讨论/战争/与/和平/等/问题”
- 组合型歧义
  - AB切分成AB或A/B
  - 如：“马上”
    - “他/骑/在/马/上”
    - “马上/过来”

中文分词-切分歧义

- 混合型歧义
  - 由交集型歧义和组合型歧义嵌套与交叉而成
  - 如：“得到达”（交集型、组合型）
    - “我/今晚/得/到达/南京”
    - “我/得到/达克宁/了 ”
    - “我/得/到/达克宁/公司/去”

中文分词-切分歧义

- 伪歧义与真歧义
  - 伪歧义字段指在任何情况下只有一种切分
    - “为人民”只有一种切分:“为/人民”，如:“为/人民/服务”
    - 根据歧义字段本身就能消歧
  - 真歧义字段指在不同的情况下有多种切分
    - “从小学”可以有多种切分：
      - “从小/学”，如：“从小/学/电脑”（“从小”是切分成“从小”还是“从/小”要根据分词规范！）
      - “从/小学”，如：“他/从/小学/毕业/后”
    - 根据歧义字段的上下文来消歧

分词方法-依据词典库和规则库

- 正向最大匹配(FMM)或逆向最大匹配(RMM)
  - 从左至右(FMM)或从右至左(RMM)，取最长的词
- 双向最大匹配
  - 分别采用FMM和RMM进行分词，能发现交集型歧义（“幼儿园/地/节目”和“幼儿/园地/节目”）
  - 如果结果一致，则认为成功；否则，采用消歧规则进行消歧
- 正向最大、逆向最小匹配
  - 正向采用FMM，逆向采用最短词，能发现组合型歧义（“他/骑/在/马上”和“他/骑/在/马/上”）
- 逐词遍历匹配
  - 在全句中取最长的词，去掉之，对剩下字符串重复该过程
- 设立切分标记
  - 收集词首字和词尾字，先把句子分成较小单位，再用某些方法切分
- 全切分
  - 获得所有可能的切分，选择最可能的切分

基于规则的歧义字段消歧方法

- 利用歧义字串、前驱字串和后继字串的句法、语义和语用信息
  - 句法信息
    - “阵风”：根据前面是否有数词来消歧。“一/阵/风/吹/过/来”、“今天/有/阵风”
  - 语义信息
    - “了解”：“他/学会/了/解/数学/难题”（“难题”一般是“解”而不是“了解”）
  - 语用信息
    - “拍卖”：“乒乓球拍卖完了”，要根据场景（上下文）来确定
- 规则的粒度
  - 基于具体的词（个性规则）
  - 基于词类、词义类（共性规则）

基于规则的歧义字段消歧方法

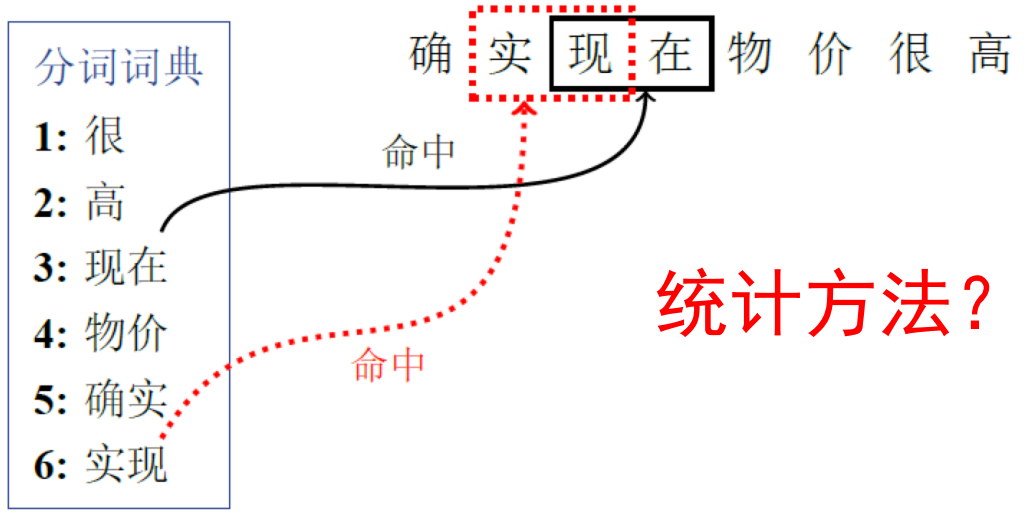

交集型分词歧义

分词带来的问题

- 组成词的字的信息丢失
- 错误的分词影响后续的工作
- 不同分词规范的分词造成分词结果不一致

不分词行吗？

词性标注

- 定义：为句子中的词标上预定义类别集合中的类（词性）
- 目标：为后续的句法/语义分析提供必要的信息
- 标注体系
- 标注方法

1 名词	5 代词	9 量词
2 动词	6 介词	10 助词
3 形容词	7 连词	11 感叹词
4 副词	8 数词	12 拟声词

一个以义为纲的词汇分类体系

——《现代汉语分类词典》*

洪桂治　苏新春

词性标注体系

- 词的分类
  - 按形态和句法功能（句法相关性）
  - 按表达的意思（语义相关性）
  - 兼顾上述二者

英语词的分类

- 开放类（open class，每类词数不限）
  - Nouns
    - 句法上：可作物主、可有限定词、有复数形式
    - 语义上：人名、地名和物名等
  - Verbs
    - 句法上：作谓语、有几种词形变化
    - 语义上：动作、过程（一系列动作）
  - Adjectives
    - 句法上：修饰Nouns等
    - 语义上：性质
  - Adverbs
    - 句法上：修饰Verbs等
    - 语义上：方向、程度、方式、时间

英语词的分类

- 封闭类（closed class，function words，每类词数有限）
  - Determiners
  - Pronouns
  - Prepositions
  - Conjunctions
  - Auxiliary verbs
  - Particles（if、not、...）
  - Numerals

词性标注的挑战

南京大学 NANJING UNIVERSITY

- 兼类词
  - 一个词具有两个或者两个以上的词性
  - 英文的Brown语料库中，10.4%的词是兼类词。例如：
    - The back door
    - On my back
    - Promise to back the bill
  - 汉语兼类词，例如：
    - 把门锁上　　买了一把锁
    - 他研究xx　　他的研究工作...
    - 由于缺少词形变化，汉语的兼类词更多！

词性标注方法

- 规则方法
  - 词典和规则提供候选词性
  - 消歧规则进行消歧

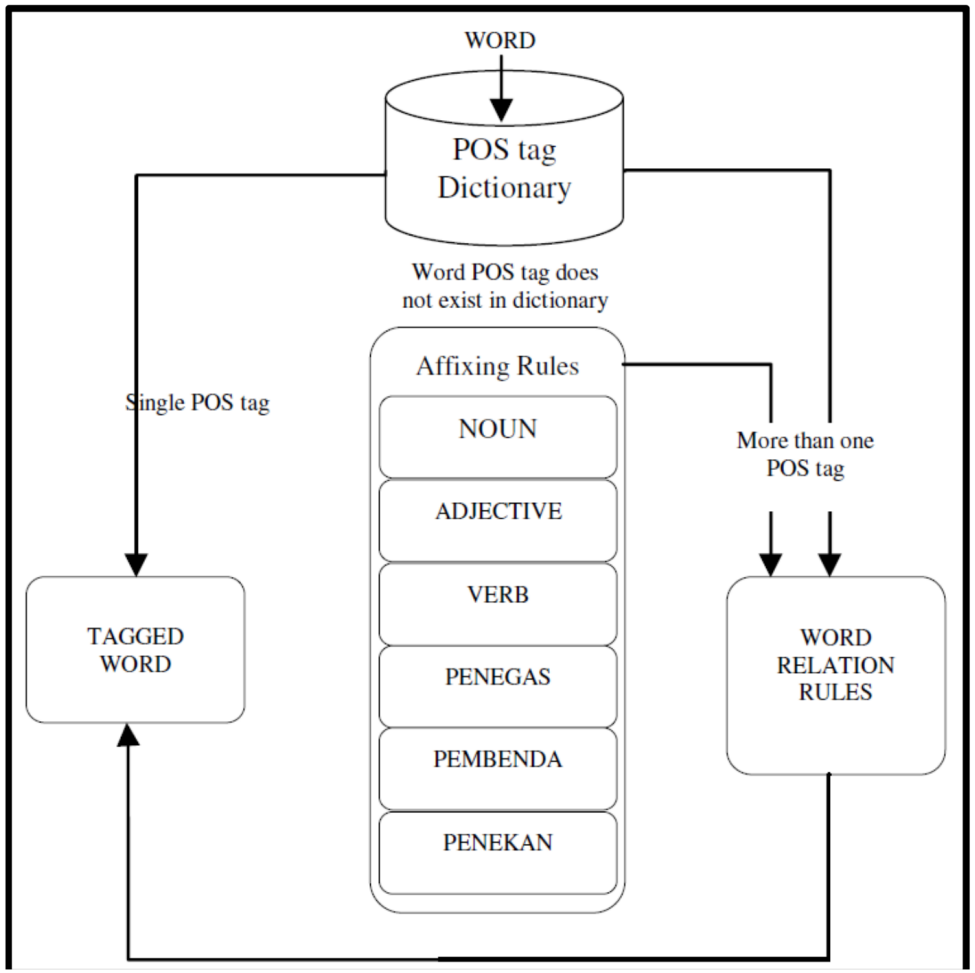

词性标注方法

- 统计方法
  - 选择最可能的词性结果
  - 训练用语料库（已标注）
- 基于转换的错误驱动方法
  - 大规模标注语料库
  - 统计学习规则
  - 用规则方法进行标注

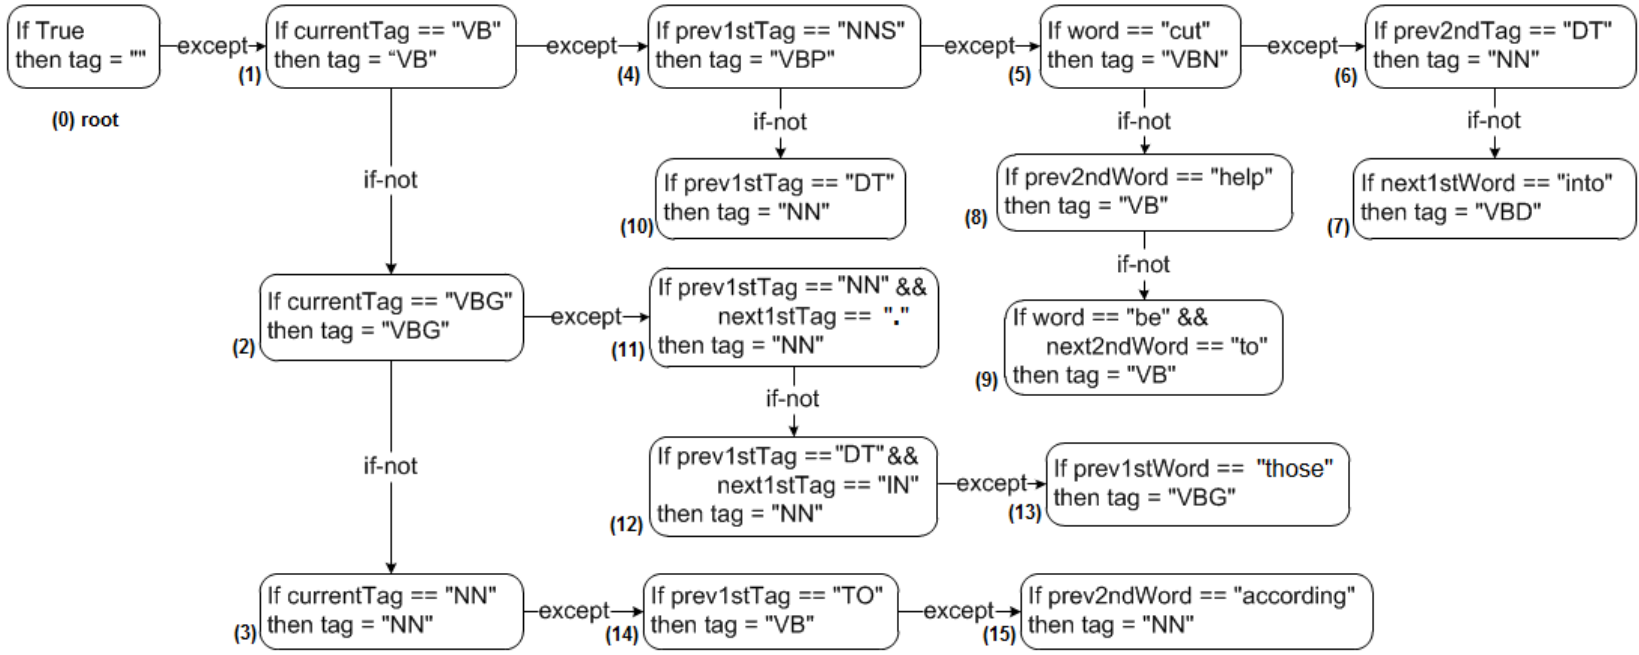

RDRPOSTagger：以二叉树的形式自动构建标注规则
https://github.com/datquocnguyen/RDRPOSTagger

命名实体识别（NER）

- 定义：识别出一句话中的所有命名实体
  - 找到实体的边界
  - 确定实体类型
- 目的：识别出实体，为后续的语义分析提供支持

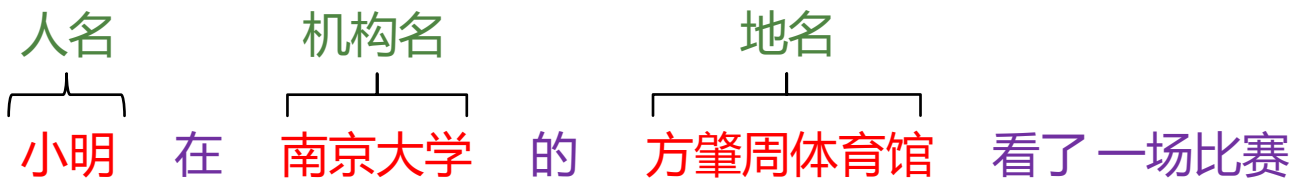

命名实体分类

- 3大类
  - 实体类、时间类、数字类
- 7小类
  - 人名、地名、机构名、时间、日期、货币量、百分数
- 其他体系（根据需要）

Type	Tag	Sample Categories	Example sentences
People	PER	people, characters	**Turing** is a giant of computer science.
Organization	ORG	companies, sports teams	The **IPCC** warned about the cyclone.
Location	LOC	regions, mountains, seas	**Mt. Sanitas** is in **Sunshine Canyon**.
Geo-Political Entity	GPE	countries, states	**Palo Alto** is raising the fees for parking.

基于规则的命名实体识别

- 核心思想
  - 匹配
  - 依赖词典、模板、正则表达式
- 人名限制成分
  - 身份词：深度学习专家Hinton
  - 指界词： Hinton参加/同意/反对
  - 标点符号：2018年图灵奖得主是Hinton、 Bengio、 Yann LeCun。

基于规则的命名实体识别

- 基于实体词表的匹配识别
  - 专家总结实体词表，利用词表进行匹配
  - 优点：速度快
  - 缺点：覆盖率有限，人力总结
  - 适合垂直领域，如医疗、金融、法律等

变化的实体（邮箱）怎么识别？？？

基于规则的命名实体识别

南京大学 NANJING UNIVERSITY

- 基于规则模板的匹配识别
  - 可以作为实体词表识别的补充
  - 分析实体词或者属性值的构词规则，并构建规则模板（正则表达式）
    - Email的表现形式通常为xxxx@xxx.com，利用“^\w+([-+.]\w+)@\w+([-.]\w+).\w+([-.]\w+)*$”来匹配Email地址
    - 利用“\d{4}[年-]\d{1,2}[月-]\d{1,2}日”的正则模板表达式来提取日期

机器翻译

- 机器翻译（Machine Translation）是一个将源语言的句子x翻译成目标语言句子y（译文）的任务。

$$\text{argmax}_y P(y|x)$$

发展历史

- 1947， Warren Weaver提出机器翻译概念（人工智能概念尚未提出）；
- 1954，第一个公开展示的俄英翻译系统，走向热潮；
- 1966，美国科学院发布ALPAC报告，走入低谷；
- 1970s，实用机器翻译系统TAUM-METEO，将英文天气翻译为法文，重燃希望；
- 1990s-2000s，统计机器翻译，逐渐火热；
- 2004，Google发布多语言在线翻译引擎，走向应用；
- 2014-至今，神经机器翻译，全面繁荣。

1954 MT system video:
https://voiceinthemachine.com/2012/06/18/can-machines-really-think/

规则翻译步骤

- 分析
  - 将源语言句子解析成一种深层的结构表示
- 转换
  - 将源语言句子的深层结构表示转换成目标语言的深层结构表示
- 生成
  - 根据目标语言的深层结构表示生成对应的目标语言句子

翻译层次

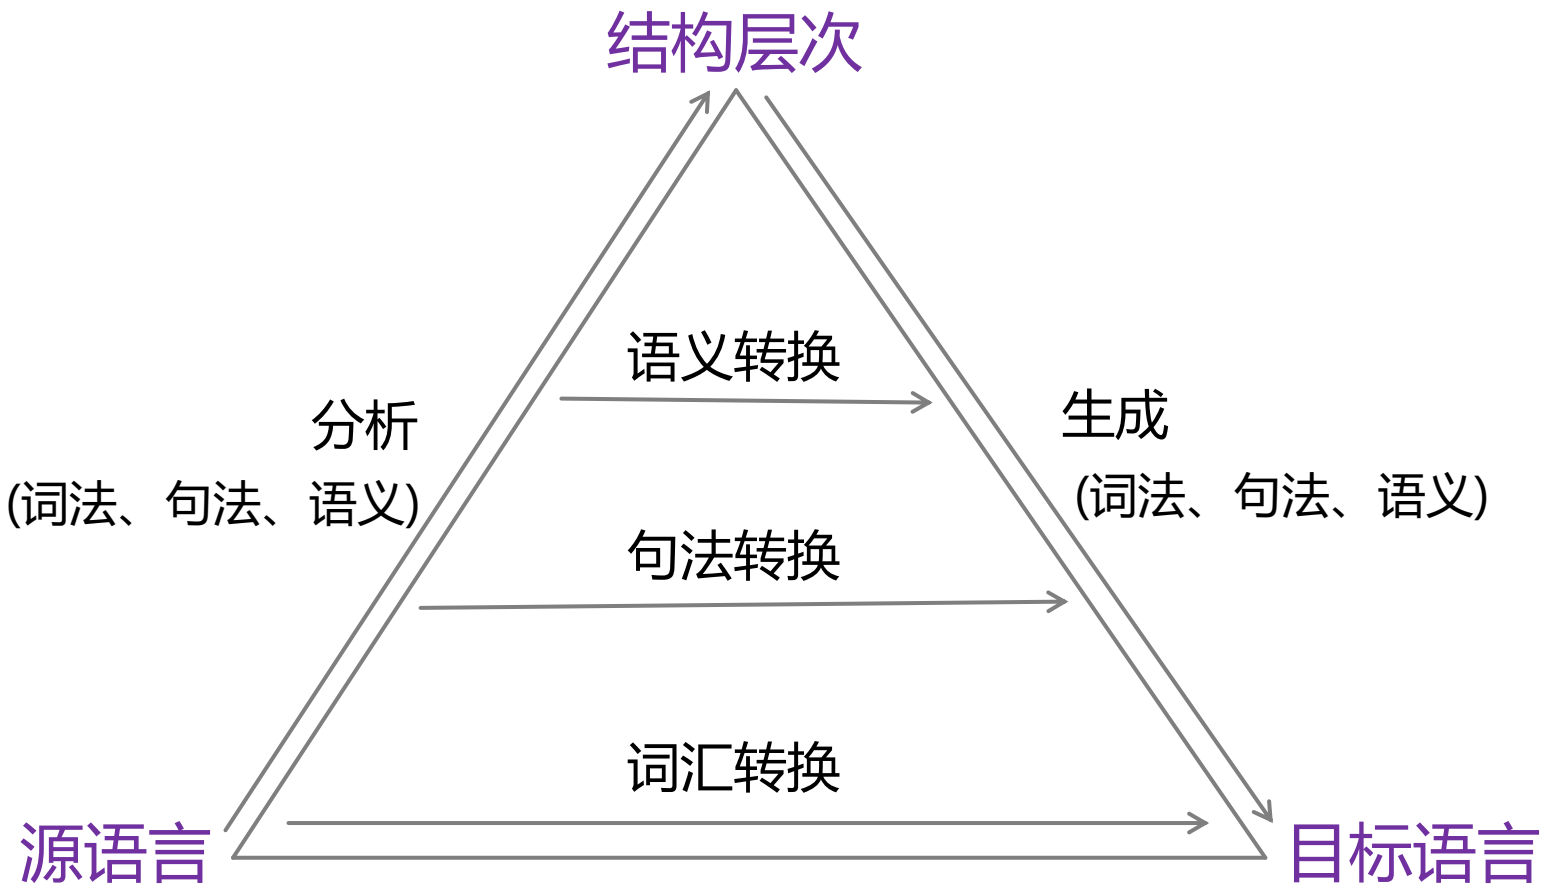

基于规则的机器翻译

- 基于词的转换翻译
- 基于句法结构转换的翻译
- 基于语义转换的翻译
- 基于中间语言（Interlingua）的翻译

基于词的转换翻译

- 翻译过程
  - 词法分析（源语言）
  - 译词选择
  - 词序调整
  - 形态（词形变化）生成
- 翻译所需的知识
  - 词法规则（源语言）
  - 双语词典及规则
  - 调序规则
  - 形态生成规则

翻译样例-词汇层次

- 词汇转换规则
  - 他 → He，在 → in，北京 → Beijing，工作 → works

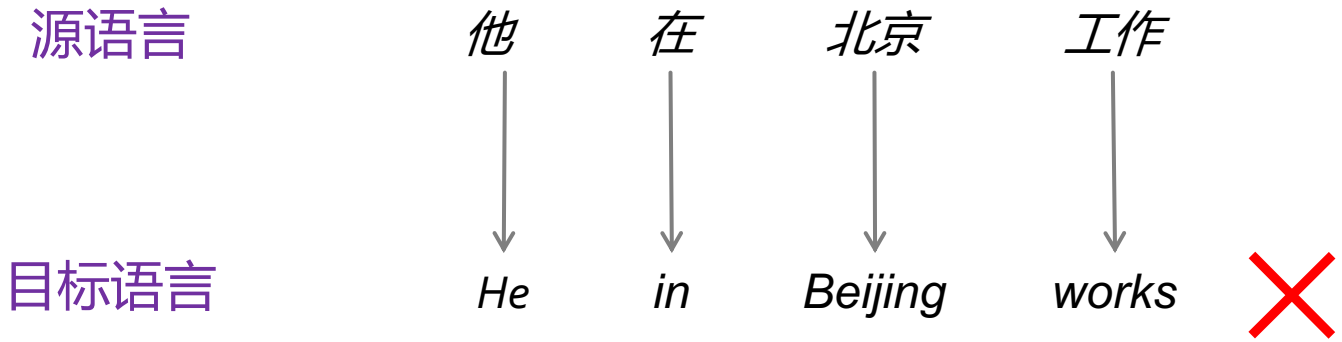

基于句法结构转换的翻译

南京大学 NANJING UNIVERSITY

- 翻译过程
  - 句法分析（源语言）
  - 递归地利用一组“树-树”的转换规则，把源语言的句法树转换成目标语言的句法树
  - 从目标语言的句法树生成目标语言句子。

翻译样例-句法层次

- 分析规则
  - NP → 他， PP → 在北京， VP → 工作， VP → PP VP， S → NP VP
- 句法转换规则
  - S (NP VP) → S (NP VP)， VP (PP VP) → VP(VP PP)
- 词汇转换规则
  - 他 → He，在 → in，北京 → Beijing，工作 → works

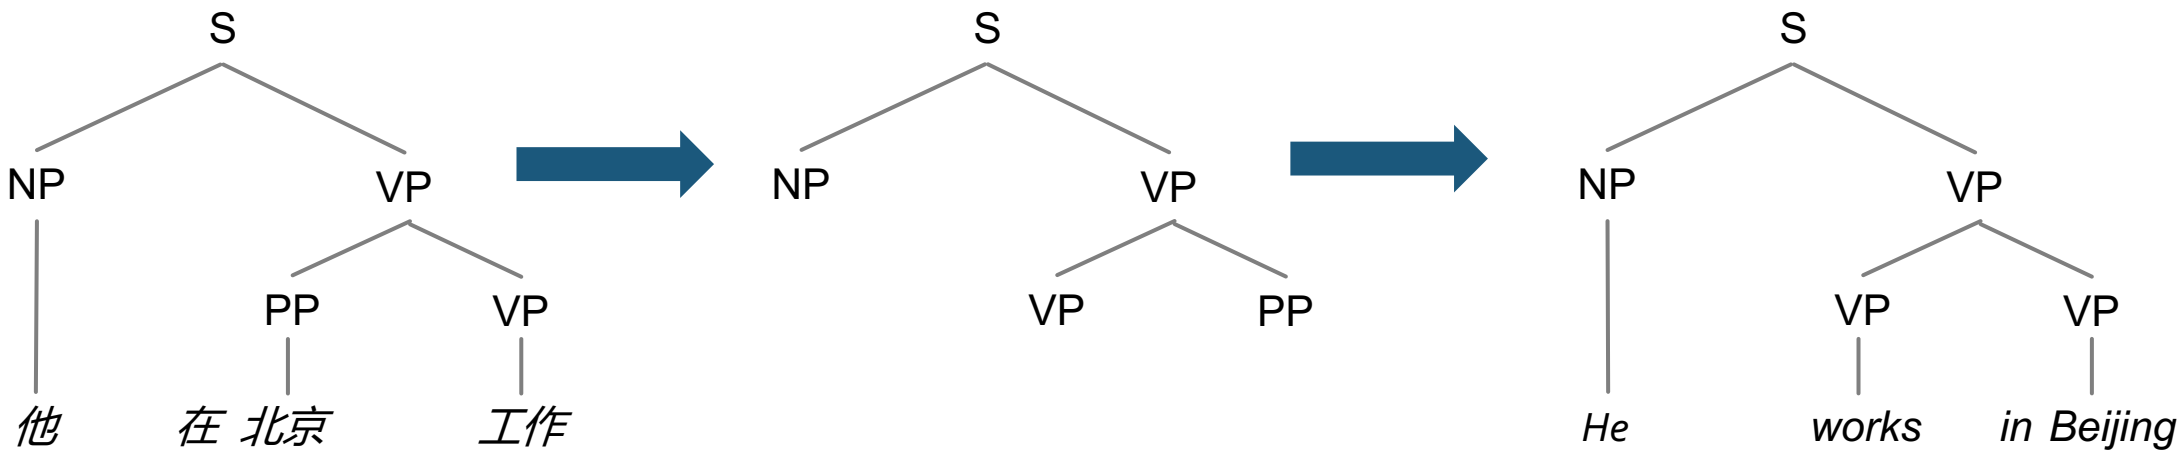

基于语义转换的翻译

- 语义表示具有较高的语言独立性，在语义级转换避免了语言相关的句法结构转换
- 转换规则需要解决不同语言之间的语义表示的对应问题：
  - 逻辑表示中的谓词转换
    - En: Susan swam across the channel.
    - Sp: Susan cruzo el canal nadando. (Susan crossed the channel swimming)
    - “运动/方式＋途径”变成“运动/途径＋方式”
  - 论旨角色表示的格转换
    - En: You like her.
    - Sp: Ella te gusta.
    - 宾语(her)变成主语(Ella)

基于中间语言(INTERLINGUA)的翻译

- 基于中间语的翻译是指对源语言进行分析，得到一个独立于源语言和目标语言的、基于概念的中间语言表示，然后从这个中间语言表示生成目标语言。
- 对于n种语言之间的翻译（多语翻译）
  - 转换翻译需要n(n-1)个模块
  - 中间语言翻译需要2n个模块

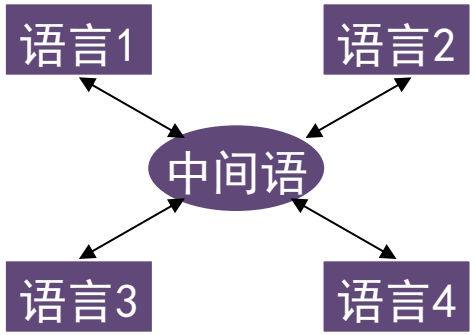

中间语言翻译

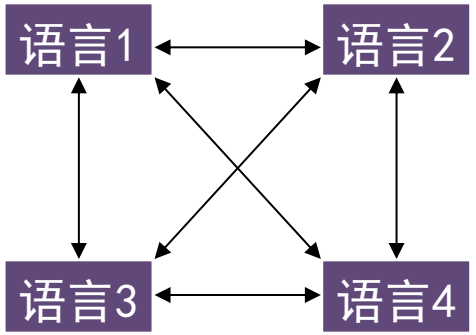

转换翻译

基于中间语言(INTERLINGUA)的翻译

南京大学 NANJING UNIVERSITY

- 中间语言翻译需解决的重要问题：
  - 一个统一的概念集及概念之间的关系集（本体论ontology所涉及的内容），使得它们对多种语言都适合
- 中间语言翻译所需要的ontology是否存在？
- 中间语言翻译加大了语言分析的难度（大量的消歧）
  - 对机器翻译来说，这样的分析是否必要？

规则方法时代

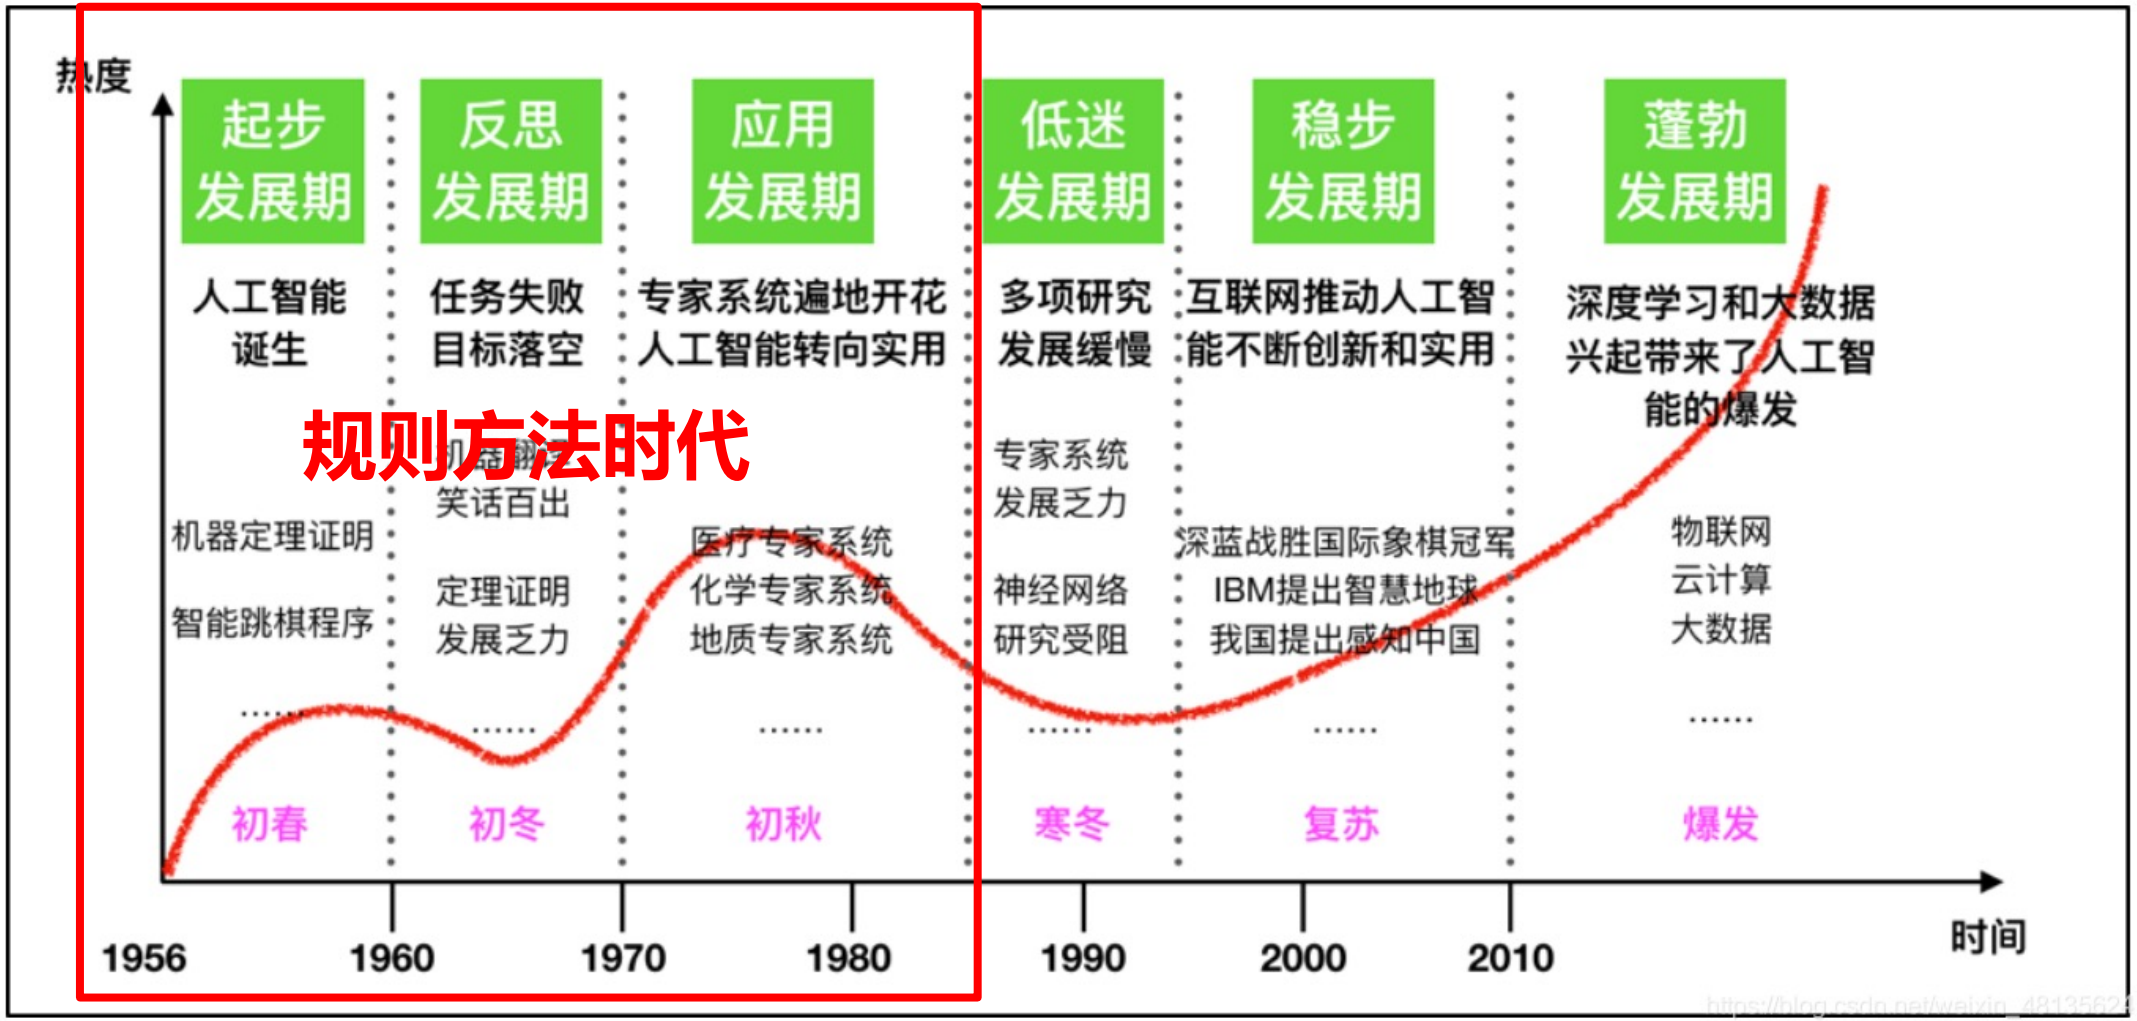
热度
起步发展期
反思发展期
应用发展期
低迷发展期
稳步发展期
蓬勃发展期
人工智能诞生
任务失败目标落空
专家系统遍地开花人工智能转向实用
多项研究发展缓慢
互联网推动人工智能不断创新和实用
深度学习和大数据兴起带来了人工智能的爆发
规则方法时代
机器翻译
笑话百出
机器定理证明
智能跳棋程序
定理证明发展乏力
医疗专家系统
化学专家系统
地质专家系统
专家系统发展乏力
神经网络研究受阻
深蓝战胜国际象棋冠军
IBM提出智慧地球
我国提出感知中国
物联网
云计算
大数据
初春
初冬
初秋
寒冬
复苏
爆发
1956
1960
1970
1980
1990
2000
2010
时间

规则方法的问题

- 规则质量依赖于语言学家的知识和经验，获取成本高
- 规则之间容易发生冲突
- 大规模规则系统维护难度大

"Anytime a linguist leaves the group the recognition rate goes up."

- Frederick Jelinek, 1988

Frederick Jelinek (1932-2010)
Researcher in Information Theory, Speech Recognition, and Natural Language Processing
Professor at Cornell 1962-1974
Head of Continuous Speech Recognition group, IBM T.J. Watson 1972-1993
Head of Center for Language and Speech Processing, JHU 1993-2010

南京大学
NANJING UNIVERSITY

Thank you！
Q&A