



南京大學

NANJING UNIVERSITY



自然语言处理

序列化标注

吴震

南京大学人工智能学院
南京大学自然语言处理研究组

2023年6月

- 背景知识
- 基于统计学习的序列化标注
 - 隐马尔可夫模型 (HMM)
 - 条件随机场 (CRF)
- 基于深度学习的序列化标注



01



背景知识

BACKGROUND

● 问题描述

- 你有一个住得很远的朋友，他每天跟你打电话告诉你他那天做了什么。你的朋友仅仅对三种活动感兴趣：公园散步，购物以及清理房间。他选择做什么事情只凭天气（晴天、下雨）。你对于他所住的地方的天气情况并不了解，因此决定根据他每天的活动情况来推测其所在地的天气情况。

状态：晴天、下雨

观测值：散步、购物、清理房间

观测序列：散步、购物、散步、清理房间、散步 ➡ 状态序列：.....

● 问题描述

- 最近一个赌场的老板生意不顺，他发现有位大叔在自己的赌场玩得一手好骰子，总能赢钱，几乎战无不胜。根据多年的经验，老板怀疑大叔使用了“偷换骰子大法”。老板是个冷静的人，看这位大叔也不是善者，不想轻易得罪他，又不想让他坏了规矩。正愁上心头，这时候进来一位名叫HMM的炼金术士，告诉老板他有一个很好的解决方案：不用近其身，只要在远处装个摄像头，把每局的骰子的点数都记录下来，然后运用其强大的数学功力，用这些数据推导出：
 - 该大叔是不是在出千？
 - 如果是在出千，那么他用了几个作弊的骰子？ 还有当前是不是在用作弊的骰子。
 - 这几个作弊骰子出现各点的概率是多少？

状态：正常骰子，作弊骰子₁，作弊骰子₂,...

观测值：骰子的点数

问题三

- 智能拼音输入法







观测序列：nan jing da xue ren gong zhi neng xue yuan



状态序列：南 京 大 学 人 工 智 能 学 院

问题总结：对于一个观测序列，如何知道观测序列背后对应的状态序列？

自然语言处理中典型的任务形式



序列化标注 (SEQUENCE LABELING)


- 定义：给定一个观测序列作为输入，输出是一个标记序列或状态序列。
- 目标：建立一个模型，使它能够对观测序列给出对应的标记序列。

输入：观测序列 $X = (x_1, x_2, \dots, x_n)$

↓ 序列化标注

输出：标记序列 $Y = (y_1, y_2, \dots, y_n)$

以词性标注为例



- 词性又称词类，是词汇的一个基本的语法属性。
- 反映了词在句子中的语法功能和意义。
- 语言学界对词性的数量、性质和普遍性进行了大量的争论
 - 封闭类
 - 开放类

- 封闭类 (closed class , function words , 每类词数有限)
 - Determiners (a/an, the, ...)
 - Pronouns (this, that, ...)
 - Prepositions (at, in, ...)
 - Conjunctions (and, but, ...)
 - Auxiliary verbs (do, does)
 - Particles (if, not, ...)
 - Numerals (one, two, ...)

- 开放类 (open class , 每类词数不限)
 - Nouns
 - 句法上：可作物主、可有限定词、有复数形式
 - 语义上：人名、地名和物名等
 - Verbs
 - 句法上：作谓语、有几种词形变化
 - 语义上：动作、过程（一系列动作）
 - Adjectives
 - 句法上：修饰Nouns等
 - 语义上：性质
 - Adverbs
 - 句法上：修饰Verbs等
 - 语义上：方向、程度、方式、时间

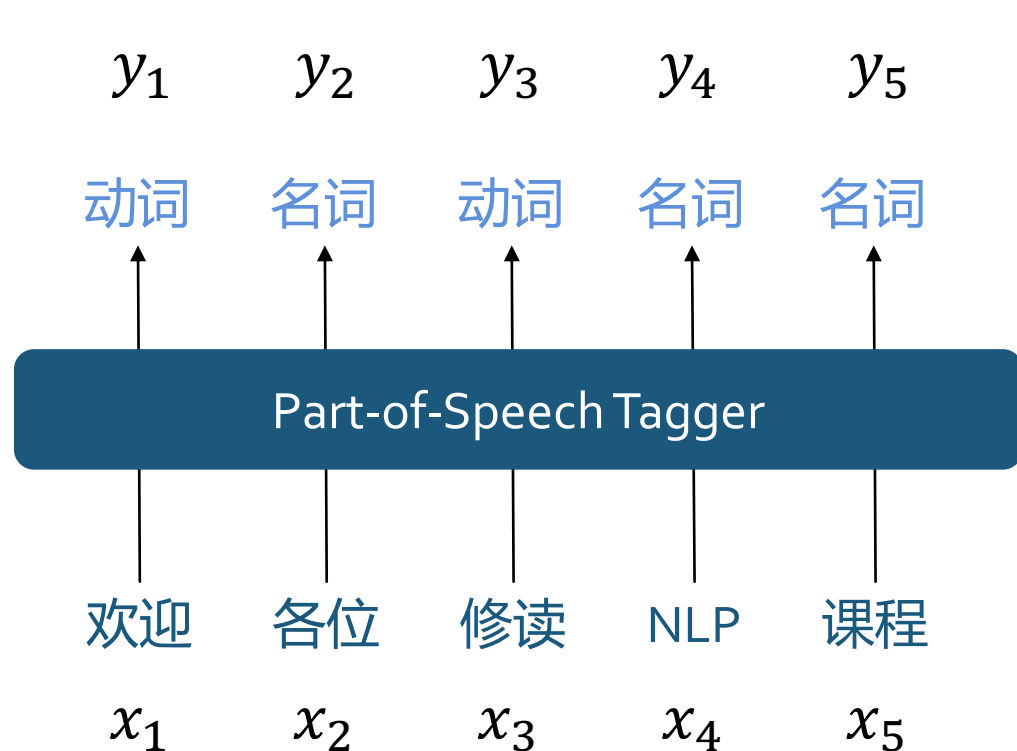
PENN树库的词性集合



Tag	Description	Example	Tag	Description	Example
CC	coordin. conjunction	<i>and, but, or</i>	SYM	symbol	<i>+, %, &</i>
CD	cardinal number	<i>one, two</i>	TO	“to”	<i>to</i>
DT	determiner	<i>a, the</i>	UH	interjection	<i>ah, oops</i>
EX	existential ‘there’	<i>there</i>	VB	verb base form	<i>eat</i>
FW	foreign word	<i>mea culpa</i>	VBD	verb past tense	<i>ate</i>
IN	preposition/sub-conj	<i>of, in, by</i>	VBG	verb gerund	<i>eating</i>
JJ	adjective	<i>yellow</i>	VCN	verb past participle	<i>eaten</i>
JJR	adj., comparative	<i>bigger</i>	VBP	verb non-3sg pres	<i>eat</i>
JJS	adj., superlative	<i>wildest</i>	VBZ	verb 3sg pres	<i>eats</i>
LS	list item marker	<i>1, 2, One</i>	WDT	wh-determiner	<i>which, that</i>
MD	modal	<i>can, should</i>	WP	wh-pronoun	<i>what, who</i>
NN	noun, sing. or mass	<i>llama</i>	WP\$	possessive wh-	<i>whose</i>
NNS	noun, plural	<i>llamas</i>	WRB	wh-adverb	<i>how, where</i>
NNP	proper noun, sing.	<i>IBM</i>	\$	dollar sign	<i>\$</i>
NNPS	proper noun, plural	<i>Carolinas</i>	#	pound sign	<i>#</i>
PDT	predeterminer	<i>all, both</i>	“	left quote	<i>‘ or “</i>
POS	possessive ending	<i>’s</i>	”	right quote	<i>’ or ”</i>
PRP	personal pronoun	<i>I, you, he</i>	(left parenthesis	<i>[, (, {, <</i>
PRP\$	possessive pronoun	<i>your, one’s</i>)	right parenthesis	<i>],), }, ></i>
RB	adverb	<i>quickly, never</i>	,	comma	<i>,</i>
RBR	adverb, comparative	<i>faster</i>	.	sentence-final punc	<i>. ! ?</i>
RBS	adverb, superlative	<i>fastest</i>	:	mid-sentence punc	<i>: ; ... - -</i>
RP	particle	<i>up, off</i>			

词性标注 (PART-OF-SPEECH TAGGING)

- 定义：给一句话中的每个词 (word)标注上词性 (Part-of-Speech)



- | | | |
|-------|------|--------|
| 1 名词 | 5 代词 | 9 量词 |
| 2 动词 | 6 介词 | 10 助词 |
| 3 形容词 | 7 连词 | 11 感叹词 |
| 4 副词 | 8 数词 | 12 拟声词 |

一个以义为纲的词汇分类体系
——《现代汉语分类词典》*

为什么需要词性标注？

- 为很多现实任务提供必要的信息
- 句法分析
 - 在对句子进行句法分析前需要知道每个词的词性
- 信息抽取
 - 帮助识别命名实体、关系
- 机器翻译
 - 帮助多义词进行更好的上下文翻译

- 兼类词

- 一个词具有两个或者两个以上的词性
- 英文的Brown语料库中，10.4%的词是兼类词。例如：
 - The **back** door
 - On my **back**
 - Promise to **back** the bill
- 汉语兼类词，例如：
 - 把门**锁**上 买了一把**锁**
 - 他**研究**xx 他的**研究**工作...
 - 由于缺少词形变化，汉语的兼类词更多！

- Brown Corpus : 语料来自于美国英语出版物上的文本 , 共500篇 , 每篇大约2000个单词 , 合计100万词 (1961)
- WSJ : 语料来自于华尔街日报 , 合计100万词 (1989)
- Switchboard : 语料来自于电话对话文本 , 合计200万词 (1990-1991)

Battle-tested/NNP industrial/JJ managers/NNS here/RB
always/RB buck/VB up/IN nervous/JJ newcomers/NNS with/IN the/DT tale/NN
of/IN the/DT first/JJ of/IN their/PP\$ countrymen/NNS to/TO visit/VB
Mexico/NNP ,/, a/DT boatload/NN of/IN samurai/NNS warriors/NNS
blown/VBN ashore/RB 375/CD years/NNS ago/RB ./.

"/" From/IN the/DT beginning/NN ,/, it/PRP took/VBD a/DT man/NN
with/IN extraordinary/JJ qualities/NNS to/TO succeed/VB in/IN Mexico/NNP ,/,
"/" says/VBZ Kimihide/NNP Takimura/NNP ,/, president/NN of/IN Mitsui/NNS
group/NN 's/POS Kensetsu/NNP Engineering/NNP Inc./NNP unit/NN ./.



02



基于统计学习的序列化标注

STATISTICAL LEARNING-BASED SEQUENCE LABELING


决定一个词词性的因素

- 从语言学角度：由词的用法以及在句中的语法功能决定


- 统计学角度：

- 和上下文的词性（前后词的标注）相关

- 和上下文单词（前后词）相关



共有16种可能



隐藏状态序列Y

教授

喜欢

画

画

观测序列X

- 词性标注：给定句子 X ，求句子对应的词性序列 Y

$$\operatorname{argmax}_Y P(Y|X) = \operatorname{argmax}_Y \frac{P(Y, X)}{P(X)}$$

$$= \operatorname{argmax}_Y P(Y, X)$$

$$= \operatorname{argmax}_Y \boxed{P(Y)P(X|Y)}$$

隐含马尔可夫模型

Hidden Markov Model , HMM

- 词性标注：给定句子 X ，求句子对应的词性序列 Y

$P(\text{名词 动词 动词 名词} \mid \text{教授 喜欢 画 画})$


$= P(\text{名词 动词 动词 名词 教授 喜欢 画 画}) / P(\text{教授 喜欢 画 画})$

$\propto P(\text{名词 动词 动词 名词 教授 喜欢 画 画})$

$= P(\text{名词 动词 动词 名词}) P(\text{教授 喜欢 画 画} \mid \text{名词 动词 动词 名词})$

- 马尔可夫链

- 描述在状态空间中，从一个状态到另一个状态转换的随机过程。



天气状态的马尔可夫链

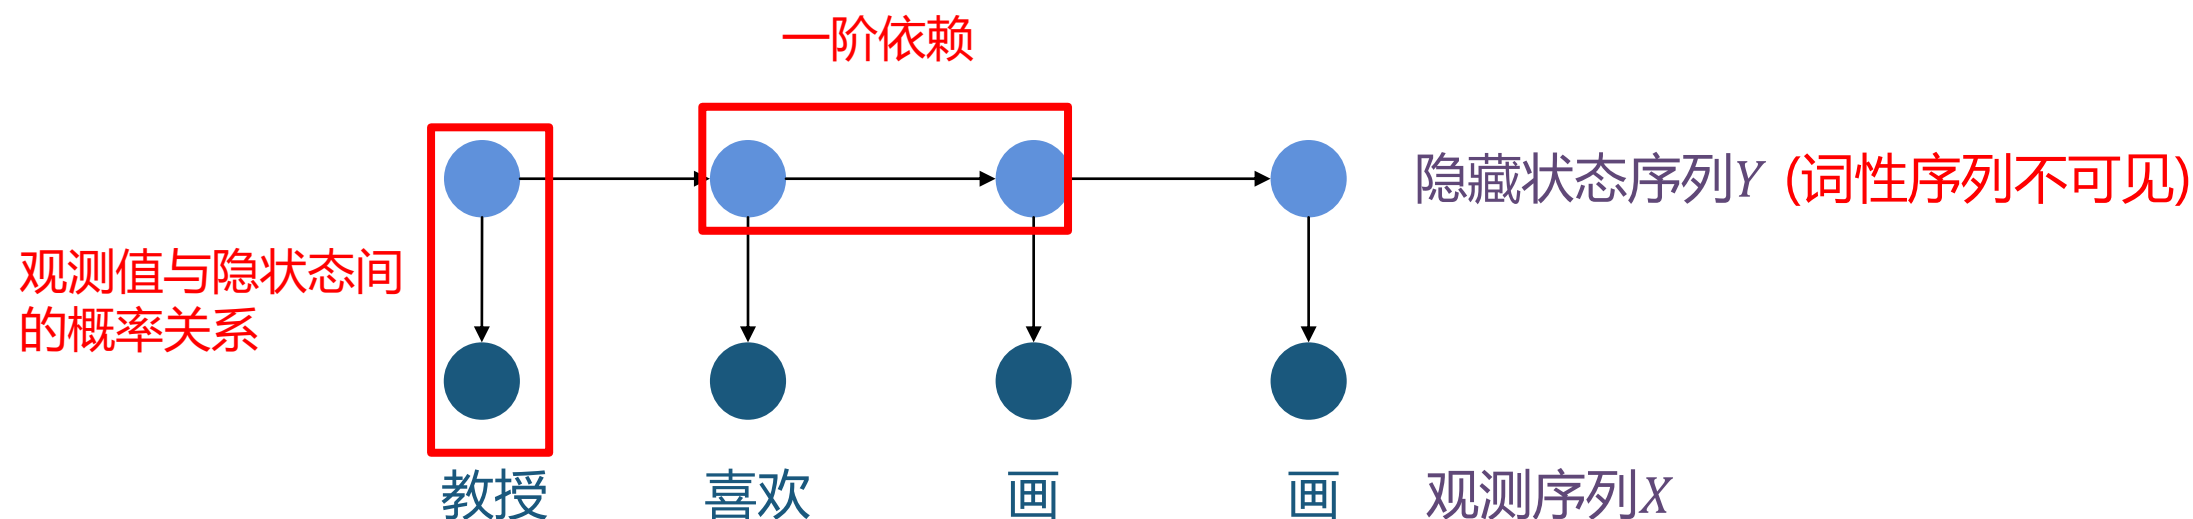
- 马尔科夫假设

- 马尔可夫链在任意时刻 t 的状态只依赖于它在前一时刻的状态，与其他时刻的状态无关

$$P(y_t | y_1, \dots, y_{t-1}) = P(y_t | y_{t-1})$$


隐含马尔可夫模型 (HMM)

- HMM是一阶马尔可夫链的扩展
 - 状态序列不可见（隐藏）
 - 隐藏的状态序列满足一阶马尔可夫链性质
 - 可见的观察值与隐藏的状态之间存在概率关系



隐含马尔可夫模型 (HMM)

- 序列化标注的统计学模型
 - 描述了由隐马尔可夫链随机生成观测序列的过程，属于生成模型。
- 时序概率模型
 - 描述由一个隐藏的马尔可夫链随机生成不可观测的状态随机序列，再由各个状态生成一个观测值，从而产生观测序列的过程。



$$P(Y, X) = P(Y)P(X|Y)$$

- 计算 $P(Y)$:

$$\begin{aligned} P(Y) &= P(y_1, y_2, \dots, y_n) \\ &= \prod_{t=1}^n P(y_t | y_1, \dots, y_{t-1}) \end{aligned}$$

- 马尔可夫假设 :

- 描述从一个状态到转换另一个状态的随机过程。该过程具备“无记忆”的性质，即当前时刻状态的概率分布只能由上一时刻的状态决定，和更久之前的状态无关。

$$P(y_t | y_1, \dots, y_{t-1}) = P(y_t | y_{t-1})$$

$P(\text{名词 动词 动词 名词}) = P(\text{名词}) * P(\text{动词}|\text{名词}) * P(\text{动词}|\text{动词}) * P(\text{名词}|\text{动词})$

- 计算 $P(X|Y)$:

$$\begin{aligned} P(X|Y) &= P(x_1, x_2, \dots, x_n | y_1, y_2, \dots, y_n) \\ &= \prod_{t=1}^n P(x_t | x_1, y_1, \dots, x_{t-1}, y_{t-1}, y_t) \end{aligned}$$

- 观测独立性假设

- 任意时刻的观测值只依赖于该时刻的马尔可夫链的状态，与其他观测及状态无关

$$P(x_t | x_1, y_1, \dots, x_{t-1}, y_{t-1}, y_t) = P(x_t | y_t)$$

$P(\text{教授 喜欢 画画} | \text{名词 动词 动词 名词}) = P(\text{教授} | \text{名词}) * P(\text{喜欢} | \text{动词}) * P(\text{画} | \text{动词}) * P(\text{画} | \text{名词})$

隐含马尔可夫模型 (HMM)

- 计算 $P(Y, X)$:

$$P(Y, X) = P(Y)P(X|Y)$$

$$= P(y_1, y_2, \dots, y_n)P(x_1, x_2, \dots, x_n|y_1, y_2, \dots, y_n)$$


$$= \prod_{t=1}^n P(y_t|y_1, \dots, y_{t-1}) \prod_{t=1}^n P(x_t|x_1, y_1, \dots, x_{t-1}, y_{t-1}, y_t)$$

$$= \prod_{t=1}^n P(y_t|y_{t-1}) \prod_{t=1}^n P(x_t|y_t)$$

$$= \prod_{t=1}^n \boxed{P(y_t|y_{t-1})} \boxed{P(x_t|y_t)}$$

状态转移概率 发射概率

状态转移概率



发射概率

隐含马尔可夫模型 (HMM)

- 计算 $P(Y, X)$:

$P(\text{名词 动词 动词 名词}, \text{教授 喜欢 画 画})$

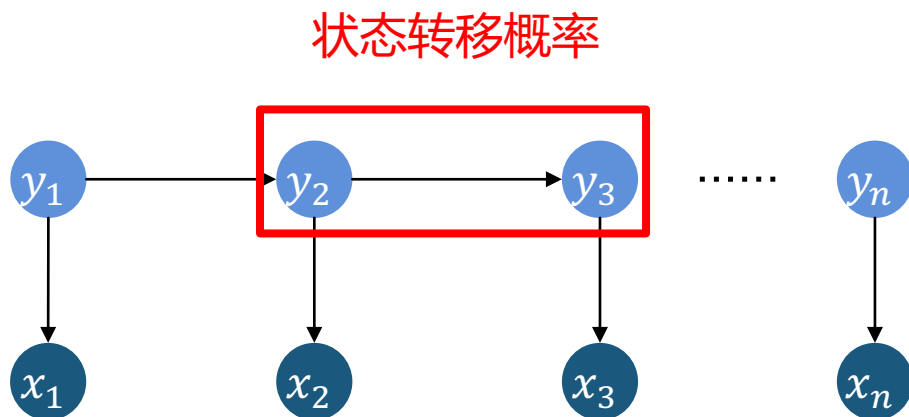
$= P(\text{名词}) * P(\text{动词}|\text{名词}) * P(\text{动词}|\text{动词}) * P(\text{名词}|\text{动词}) * P(\text{教授}|\text{名词}) * P(\text{喜欢}|\text{动词}) * P(\text{画}|\text{动词})$
 $* P(\text{画}|\text{名词})$

隐含马尔可夫模型 (HMM)

- 状态集合 $\mathbb{Q} = \{q_1, q_2, \dots, q_Q\}$, 观测值集合 $\mathbb{V} = \{v_1, v_2, \dots, v_V\}$
 - Q 和 V 分别表示状态数量和观测值数量
- $Y = (y_1, y_2, \dots, y_n)$ 是长度为 n 的状态序列 , $X = (x_1, x_2, \dots, x_n)$ 是对应的观测序列
 - $y_t \in \mathbb{Q}$ 是一个随机变量 , 代表一个可能的状态值
 - $x_t \in \mathbb{V}$ 是一个随机变量 , 代表一个可能的观测值

隐含马尔可夫模型 (HMM)

- 状态转移概率矩阵 \mathbf{A} : 表示状态之间的转移概率
 - 其中 $a_{i,j} = P(y_{t+1} = q_j | y_t = q_i)$, 表示在 t 时刻处于状态 q_i 的条件下 , 在 $t + 1$ 时刻转移到 q_j 的概率
P(动词|名词)




$$\mathbf{A} = \begin{bmatrix} a_{1,1} & a_{1,2} & \cdots & a_{1,Q} \\ a_{2,1} & a_{2,2} & \cdots & a_{2,Q} \\ \vdots & \vdots & \vdots & \vdots \\ a_{Q,1} & a_{Q,2} & \cdots & a_{Q,Q} \end{bmatrix}$$

隐含马尔可夫模型 (HMM)

- 发射概率矩阵 **B** : 表示某个状态下生成某个观测值的概率
 - 其中 $b_j(k) = P(x_t = v_k | y_t = q_j)$, 表示 t 时刻处于状态 q_j 的条件下生成观测值 v_k 的概率

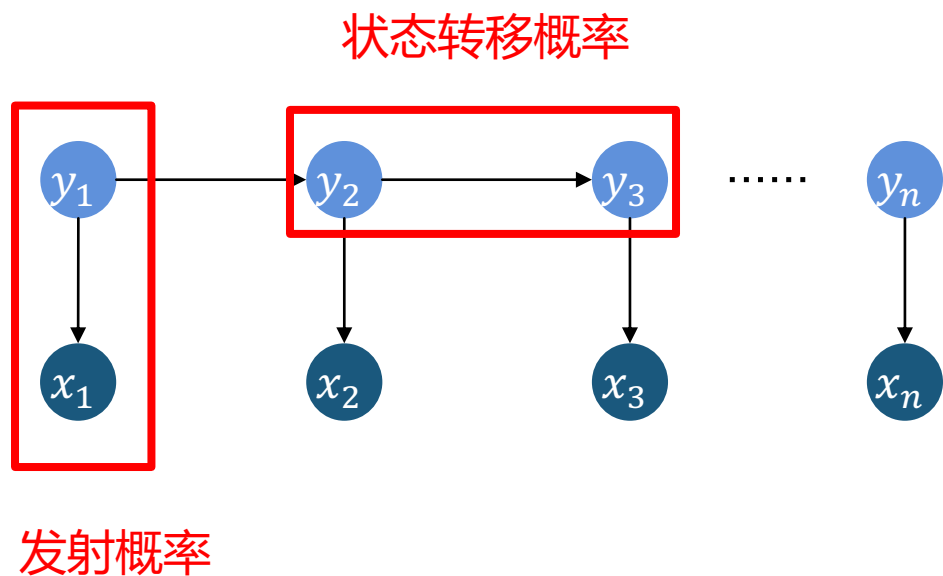
$$\mathbf{B} = \begin{bmatrix} b_1(1) & b_1(2) & \dots & b_1(V) \\ b_2(1) & b_2(2) & \dots & b_2(V) \\ \vdots & \vdots & \vdots & \vdots \\ b_Q(1) & b_Q(2) & \dots & b_Q(V) \end{bmatrix}$$



- 初始状态概率 π : $\pi = (\pi_1, \pi_2, \dots, \pi_Q)$
 - $\pi_i = P(y_1 = q_i)$ 表示开始时刻 $t = 1$ 时处于状态 q_i 的概率
 - $\sum_{i=1}^Q \pi_i = 1$

隐含马尔可夫模型 (HMM)

- 隐马尔可夫模型由初始状态概率 π 、状态转移矩阵 \mathbf{A} 、以及发射概率矩阵 \mathbf{B} 决定。一个隐马尔可夫模型可用三元符号表示： $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$
 - 初始状态概率 π 和状态转移矩阵 \mathbf{A} 确定了隐藏的马尔可夫链，生成了不可观测的状态序列；
 - 观测概率矩阵 \mathbf{B} 确定了如何从状态生成观测值，与状态序列一起确定了如何产生观测序列。



$$\begin{aligned} P(Y, X) &= P(Y)P(X|Y) \\ &= \prod_{t=1}^n P(y_t|y_{t-1})P(x_t|y_t) \end{aligned}$$

词性标注的HMM模型定义



- HMM : $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$
- 状态集合 \mathcal{Q} : 预先定义的词性标签集
- 观测值集合 \mathcal{V} : 词表集合
- 状态转移概率矩阵 \mathbf{A} : 词性之间的转移概率
- 发射概率矩阵 \mathbf{B} : 某个词性生成某个词的概率
- 初始状态概率 π : 以某个词性作为开始状态的概率

- 概率计算
 - 给定HMM模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$ 和观测序列 $X = (x_1, x_2, \dots, x_n)$, 计算观测序列 X 出现的概率 $P(X|\lambda)$ $P(\text{教授 喜欢 画画} | \lambda)$
- 模型学习 (参数估计)
 - 已知观测序列 $X = (x_1, x_2, \dots, x_n)$, 估计HMM模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$ 的参数 , 使得该模型下观测序列的概率 $P(X|\lambda)$ 最大。 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$
- 预测 (解码)
 - 已知HMM模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$ 和观测序列 $X = (x_1, x_2, \dots, x_n)$, 求该观测序列对应的最可能的状态序列 $Y = (y_1, y_2, \dots, y_n)$ $\operatorname{argmax}_Y P(Y | \text{教授 喜欢 画画}, \lambda)$

- 概率计算

- 给定HMM模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$ 和观测序列 $X = (x_1, x_2, \dots, x_n)$, 计算观测序列 X 出现的概率 $P(X|\lambda)$

- 直接计算法

- 枚举所有长度为n的状态序列，计算它们生成观测序列的概率并求和

$$P(X|\lambda) = \sum_{y_1, y_2, \dots, y_n} \pi_{y_1} \prod_{t=1}^n a_{y_t, y_{t+1}} b_{y_t}(x_t)$$

计算复杂度 $O(n \times Q^n)$, 不可行

- 定义前向概率
 - 给定HMM模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$, 定义到 t 时刻部分观测序列为 x_1, x_2, \dots, x_t 且状态为 q_i 的概率为前向概率, 记作:

$$\alpha_t(i) = P(x_1, x_2, \dots, x_t, y_t = q_i | \lambda)$$

HMM的概率计算-前向算法

- 输入：隐马尔可夫模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$, 观测序列 $X = (x_1, x_2, \dots, x_n)$
- 输出：观测序列概率 $P(X|\lambda)$
- 算法流程：

- 初始化：

$$\alpha_1(i) = \pi_i b_i(x_1), \quad i = 1, 2, \dots, Q$$

- 递推：

$$\alpha_t(i) = \left[\sum_{j=1}^Q \alpha_{t-1}(j) a_{j,i} \right] b_i(x_t) \quad i = 1, 2, \dots, Q \quad t = 2, \dots, n$$

- 终止：

计算复杂度 $O(n \times Q^2)$

$$P(X|\lambda) = \sum_{i=1}^Q \alpha_n(i), \quad i = 1, 2, \dots, Q$$

- 定义后向概率
 - 给定HMM模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$, 在 t 时刻状态为 q_i 的条件下 , $t + 1$ 时刻到 n 时刻部分的观测序列为 $x_{t+1}, x_{t+2}, \dots, x_n$ 的概率为后向概率 , 记作 :

$$\beta_t(i) = P(x_{t+1}, x_{t+2}, \dots, x_n | y_t = q_i, \lambda)$$

HMM的概率计算-后向算法

- 输入：隐马尔可夫模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$, 观测序列 $X = (x_1, x_2, \dots, x_n)$
- 输出：观测序列概率 $P(X|\lambda)$
- 算法流程：

- 初始化：

$$\beta_n(i) = 1, \quad i = 1, 2, \dots, Q$$

- 递推：

$$\beta_t(i) = \sum_{j=1}^Q a_{i,j} b_j(x_{t+1}) \beta_{t+1}(j) \quad i = 1, 2, \dots, Q \quad t = n, n-1, \dots, 1$$

- 终止：

计算复杂度 $O(n \times Q^2)$

$$P(X|\lambda) = \sum_{i=1}^Q \pi_i \beta_1(i) b_i(x_1), \quad i = 1, 2, \dots, Q$$

- 模型学习（参数估计）
 - 已知观测序列 $X = (x_1, x_2, \dots, x_n)$ ，估计模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$ 的参数，使得该模型下观测序列的概率 $P(X|\lambda)$ 最大。
- 根据训练数据的不同，隐马尔可夫模型的学习方法也不同
 - 监督学习：训练数据包括观测序列和对应的状态序列，通过监督学习来学习隐马尔可夫模型。
 - 无监督学习：训练数据仅包括观测序列，通过无监督学习来学习隐马尔可夫模型。

HMM的参数估计—监督学习

- 假设数据集为 $\mathbb{D} = \{(X_1, Y_1), (X_2, Y_2), \dots, (X_N, Y_N)\}$, 其中 :
 - X_1, \dots, X_N 为 N 个观测序列 ; Y_1, \dots, Y_N 为对应的 N 个状态序列。
 - 序列 X_k , Y_k 的长度为 n_k 。
- 估计转移概率 $a_{i,j}$
 - 设样本中前一时刻处于状态 q_i 、 且后一时刻处于 q_j 的频数为 $A_{i,j}$, 则转移概率 $a_{i,j}$ 的估计是 :

$$a_{i,j} = \frac{A_{i,j}}{\sum_{u=1}^Q A_{i,u}}, \quad i = 1, 2, \dots, Q; \quad j = 1, 2, \dots, Q$$

- 估计转移概率 $a_{i,j}$

- 设样本中前一时刻处于状态 q_i 、且后一时刻处于 q_j 的频数为 $A_{i,j}$ ，则转移概率 $a_{i,j}$ 的估计是：

$$a_{i,j} = \frac{A_{i,j}}{\sum_{u=1}^Q A_{i,u}}, \quad i = 1, 2, \dots, Q; \quad j = 1, 2, \dots, Q$$

$$a_{\text{动词,名词}} = \frac{A_{\text{动词,名词}}}{A_{\text{动词}}} = \frac{10471}{13124} = 0.797$$

- 估计观测概率 $b_j(k)$
 - 设样本中状态为 q_j 且其对应观测值为 v_k 的频数为 $B_{j,k}$, 则状态为 q_j 并且观测值为 v_k 的概率 $b_j(k)$ 的估计为 :

$$b_j(k) = \frac{B_{j,k}}{\sum_{v=1}^V B_{j,v}}, \quad j = 1, 2, \dots, Q; \quad k = 1, 2, \dots, V$$

$$b_{\text{动词}}(\text{画}) = \frac{B_{\text{动词,画}}}{B_{\text{动词}}} = \frac{4046}{13124} = 0.308$$

- 估计初始状态概率 π_i
 - 设样本中初始时刻 ($t = 1$) 处于状态 q_i 的频数为 C_i , 则初始状态概率 π_i 的估计为 :

$$\pi_i = \frac{C_i}{\sum_{j=1}^Q C_j}, \quad i = 1, 2, \dots, Q;$$

$$\pi_{\text{动词}} = \frac{C_{\text{动词}}}{\sum_{j=1}^Q C_j} = \frac{3728}{8429} = 0.442$$

HMM的一些概率和期望值

- 给定HMM模型 λ 和观测序列 X ，在 t 时刻处于状态 q_i 的概率为：

$$\gamma_t(i) = P(y_t = q_i | X, \lambda)$$

- 由前向概率 $\alpha_t(i)$ 和后向概率 $\beta_t(i)$ 可知：

$$\alpha_t(i)\beta_t(i) = P(y_t = q_i, X | \lambda)$$

- 可得到：

$$\gamma_t(i) = \frac{P(y_t = q_i, X | \lambda)}{P(X | \lambda)} = \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^Q \alpha_t(i)\beta_t(i)}$$

- 给定HMM模型 λ 和观测序列 X ，在 t 时刻处于状态 q_i 且 $t + 1$ 时刻处于状态 q_j 的概率为：

$$\zeta_t(i, j) = P(y_t = q_i, y_{t+1} = q_j | X, \lambda)$$

- 由前向概率 $\alpha_t(i)$ 和后向概率 $\beta_t(i)$ 可知：

$$P(y_t = q_i, y_{t+1} = q_j | X, \lambda) = \alpha_t(i) a_{ij} b_j(x_{t+1}) \beta_{t+1}(j)$$

- 可得到：

$$\zeta_t(i, j) = \frac{P(y_t = q_i, y_{t+1} = q_j | X, \lambda)}{P(X | \lambda)} = \frac{\alpha_t(i) a_{ij} b_j(x_{t+1}) \beta_{t+1}(j)}{\sum_{i=1}^Q \sum_{j=1}^Q \alpha_t(i) a_{ij} b_j(x_{t+1}) \beta_{t+1}(j)}$$

HMM的一些概率和期望值

- 给定观测序列 X ，状态 q_i 出现的期望值为：

$$\sum_{t=1}^n \gamma_t(i)$$

- 给定观测序列 X ，由状态 q_i 转移的期望值为：

$$\sum_{t=1}^{n-1} \gamma_t(i)$$

- 给定观测序列 X ，由状态 q_i 转移到状态 q_j 的期望值为：

$$\sum_{t=1}^{n-1} \zeta_t(i, j)$$

HMM的学习问题—无监督学习

- 输入：观测序列 $X = (x_1, x_2, \dots, x_n)$

- 输出：HMM模型参数

Baum-Welch算法

- 算法流程：

- 初始化：对 $m = 0$ ，选取 $a_{ij}^{(0)}, b_j(k)^{(0)}, \pi_i^{(0)}$ ，得到模型 $\lambda^{(0)} = (A^{(0)}, B^{(0)}, \pi^{(0)})$

- 递推：对于 $m = 1, 2, \dots$

$$a_{ij}^{(m+1)} = \frac{\sum_{t=1}^{n-1} \zeta_t(i, j)}{\sum_{t=1}^{n-1} \gamma_t(i)} \quad b_j(k)^{(m+1)} = \frac{\sum_{t=1, x_t=k}^n \gamma_t(j)}{\sum_{t=1}^n \gamma_t(j)} \quad \pi_i^{(m+1)} = \gamma_0(i)$$

- 上述各式右边模型 $\lambda^{(m)} = (A^{(m)}, B^{(m)}, \pi^{(m)})$ 计算

- 终止，得到HMM模型参数 $\lambda^{(m+1)} = (A^{(m+1)}, B^{(m+1)}, \pi^{(m+1)})$ 计算

- 预测（解码）

- 已知模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$ 和观测序列 $X(x_1, x_2, \dots, x_n)$ ，求该观测序列对应的最可能的状态序列 $Y = (y_1, y_2, \dots, y_n)$


- 计算目标

$$\operatorname{argmax}_{y_1, y_2, \dots, y_n} P(y_1, y_2, \dots, y_n, x_1, x_2, \dots, x_n) = \operatorname{argmax}_{y_1, y_2, \dots, y_n} \pi_{y_1} \prod_{t=1}^n a_{y_t, y_{t+1}} b_{y_t}(x_t)$$


HMM的模型预测（解码）

- 计算目标

$$\operatorname{argmax}_{y_1, y_2, \dots, y_n} P(y_1, y_2, \dots, y_n, x_1, x_2, \dots, x_n) = \operatorname{argmax}_{y_1, y_2, \dots, y_n} \pi_{y_1} \prod_{t=1}^n a_{y_t, y_{t+1}} b_{y_t}(x_t)$$




- 算法思想：最优子结构
 - 根据动态规划原理，最优路径具有这样的特性：如果最优路径在时刻 t 通过结点 y_t^* ，则这一路径从结点 y_t^* 到终点 y_n^* 的部分路径，对于从 y_t^* 到 y_n^* 的所有可能路径来说，也必须是最优的。



HMM的预测问题—维特比算法

- 对于观测序列 $X = (x_1, x_2, \dots, x_n)$
 - t 时刻状态为 q_i 且已观测序列为 x_1, x_2, \dots, x_t 的所有可能路径 (y_1, y_2, \dots, y_t) 中概率最大值为：

$$\delta_t(i) = \max_{y_1, \dots, y_{t-1}} P(y_1, \dots, y_{t-1}, y_t = q_i, x_1, \dots, x_t), \quad i = 1, 2, \dots, Q$$




HMM的预测问题—维特比算法

- 对于观测序列 $X = (x_1, x_2, \dots, x_n)$

- 得到变量 δ 的递推公式

$$\delta_t(i) = \max_{y_1, \dots, y_{t-1}} P(y_1, \dots, y_{t-1}, y_t = q_i, x_1, \dots, x_t) = \max_{1 \leq j \leq Q} \delta_{t-1}(j) \times a_{j,i} \times b_i(x_t)$$



- t 时刻状态为 q_i 的所有单个路径中概率最大的路径的第 $t-1$ 个结点为：

$$\Psi_t(i) = \operatorname{argmax}_{1 \leq j \leq Q} \delta_{t-1}(j) a_{j,i}, \quad i = 1, 2, \dots, Q$$

HMM的预测问题—维特比算法


- 输入：隐马尔可夫模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$, 观测序列 $X = (x_1, x_2, \dots, x_n)$
- 输出：最优的状态路径 $Y^* = (y_1^*, y_2^*, \dots, y_n^*)$
- 算法流程：
 - 初始化： $\delta_1(i) = \pi_i b_i(x_1), \Psi_1(i) = 0, \quad i = 1, 2, \dots, Q$
 - 递推：
$$\delta_t(i) = \max_{1 \leq j \leq Q} \delta_{t-1}(j) \times a_{j,i} \times b_i(x_t)$$
$$\Psi_t(i) = \operatorname{argmax}_{1 \leq j \leq Q} \delta_{t-1}(j) a_{j,i} \quad i = 1, 2, \dots, Q; \quad t = 2, \dots, n$$
 - 终止： $P^* = \max_{1 \leq i \leq Q} \delta_n(i), \quad y_n^* = \operatorname{argmax}_{1 \leq j \leq Q} \delta_{t-1}(j) a_{j,i}$
 - 最优路径回溯： $y_t^* = \Psi_{t+1}(y_{t+1}^*), \quad t = n-1, \dots, 1$
 - 获得最优路径 $Y^* = (y_1^*, y_2^*, \dots, y_T^*)$ 。

HMM生成观测序列的过程

- 输入：隐马尔可夫模型 $\lambda = (\mathbf{A}, \mathbf{B}, \pi)$ 和观测序列长度 n
- 输出：观测序列 $X = (x_1, x_2, \dots, x_n)$
- 算法步骤：
 - 按照初始状态分布 π 产生状态 y_1
 - 令 $t = 1$ ，开始迭代。迭代条件： $t \leq n$ 。迭代步骤为：
 - 按照状态 y_t 的观测概率分布 $b_j(k)$ 生成观测值 x_t
 - 按照状态 y_t 的状态转移分布 $a_{i,j}$ 产生状态 y_{t+1}
 - 令 $t = t + 1$

- 由于观测独立性假设（任意时刻的观测只依赖于该时刻的马尔可夫链的状态），很难融入更多的特征（如上下文）以表示复杂的关系
- Label bias问题：由于马尔可夫假设使得在计算转移概率时做了局部归一化，算法倾向于选择分支较少的状态

- 如何从所有可能中找到最合理的词性标注序列？



词性序列共有16种可能

观测序列

基于HMM的词性标注方法

- 建模方法


- 由一个隐藏的马尔可夫链随机生成不可观测的状态（词性）随机序列，再由各个状态（词性）生成一个观测值（单词），从而产生观测序列（句子）的过程。

$$\operatorname{argmax}_Y P(Y|X) = \operatorname{argmax}_Y \frac{P(Y, X)}{P(X)}$$

$$= \operatorname{argmax}_Y P(Y)P(X|Y)$$

$$= \operatorname{argmax}_{y_1, \dots, y_n} \prod_{t=1}^n \boxed{P(y_t|y_{t-1})} \boxed{P(x_t|y_t)}$$

状态转移概率 发射概率



共有16种可能

隐藏状态序列Y


观测序列X

HMM方法的问题

- 只考虑当前时刻的特征，无法融入更多的特征（如上下文）以表示复杂的关系
- 转移概率做了局部归一化，容易产生标签偏置问题

$$P(y_t|y_{t-1})P(x_t|y_t)$$

状态转移概率 发射概率



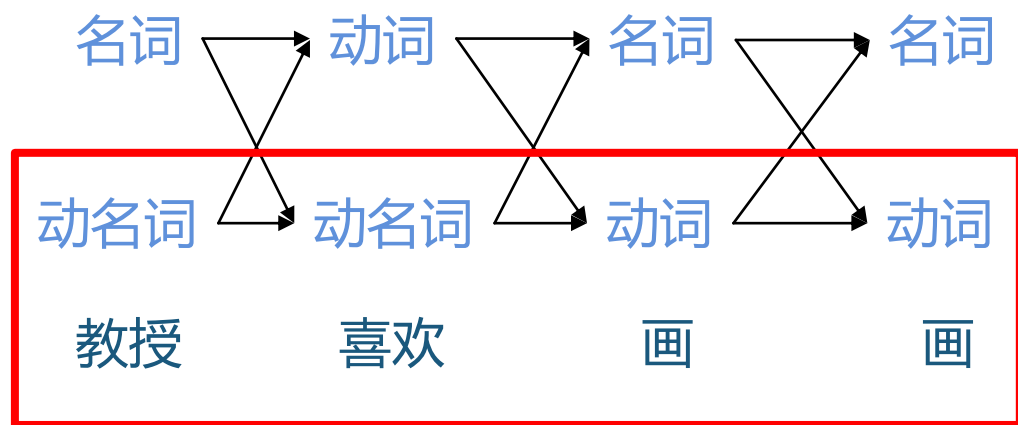
共有16种可能

隐藏状态序列Y

观测序列X

换个思路

- 能不能直接判断一个词性序列是否合理？
 - 给定句子，直接对词性序列进行打分，打分越高的越合理



词性序列共有16种可能

Score

观测序列

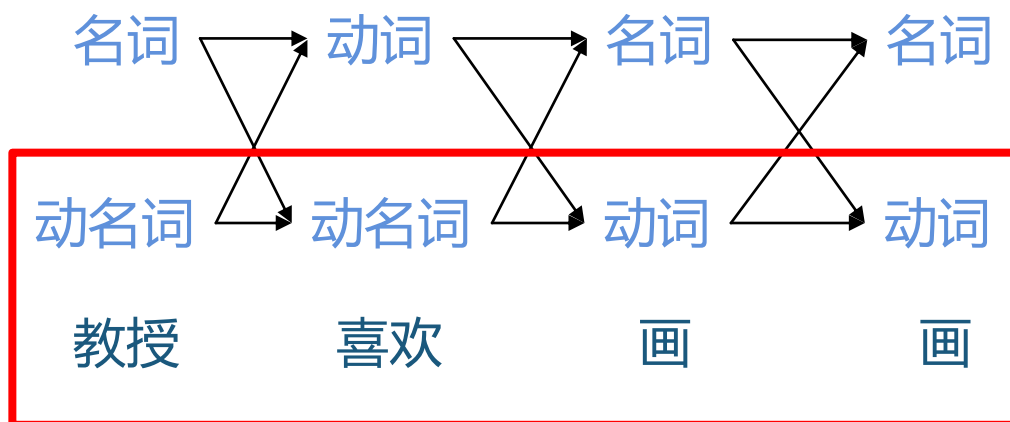
- 隐含马尔可夫模型 (HMM)是生成式模型

$$\begin{aligned}\operatorname{argmax}_Y P(Y|X) &= \operatorname{argmax}_Y \frac{P(Y, X)}{P(X)} \\ &= \operatorname{argmax}_Y P(Y)P(X|Y) \\ &= \operatorname{argmax}_{y_1, \dots, y_n} \prod_{t=1}^n P(y_t|y_{t-1})P(x_t|y_t)\end{aligned}$$

- 条件随机场 (Conditional Random Fields, CRF) 是一种判别式模型
 - 直接建模条件概率

$$\operatorname{argmax}_Y P(Y|X)$$

- 如何对词性标注序列打分？
 - 凡是介词后面是连词的标注序列（不合理），给它打负分 一个特征函数
- 定义一个特征函数集合，用这个特征函数集合来为一个标注序列打分，并据此选出最合理的标注序列
 - 每一个特征函数都可以用来为标注序列打分，把集合中所有特征函数对同一个标注序列的打分综合起来，就能得到最终打分




词性序列共有16种可能

Score

观测序列

- 优势
 - CRF使用特征函数来考虑更复杂、更抽象的特征
 - HMM只局限于转移概率特征和发射概率特征
- 特征函数举例：
 - $I(x_t = the, y_t = \text{DET})$
 - $I(y_t = \text{PROPN}, x_{t+1} = \text{Street}, y_{t-1} = \text{NUM})$
 - $I(y_t = \text{VERB}, y_{t-1} = \text{AUX})$
- 特征模板举例：
 - $\langle y_t, y_{t-1} \rangle$
 - $\langle y_t, x_{t-1}, x_{t+2} \rangle$
 -


- 特征函数 $F_k(X, Y)$
 - 第 k 个特征函数对于句子为 X 、词性标注为 Y 的打分
 - 可以考虑句子内部、词性内部、以及句子和词性之间的复杂关系
 - 例如：第一个词和最后一个词的词性可能需要满足特定的关系
- 模型目标
 - w_k 为第 k 个特征函数的权重，权重越大表明该特征越重要



$$P(Y|X) = \frac{\exp(\sum_{k=1}^K w_k F_k(X, Y))}{\sum_{Y'} \exp(\sum_{k=1}^K w_k F_k(X, Y'))}$$

考虑所有可能的关系会
导致建模非常复杂

- 线性链特征函数 $f_k(X, t, y_{t-1}, y_t)$
 - X : 需要标注的句子
 - t : 句子中的第 t 个单词
 - y_{t-1} : 表示要评分的标注序列中第 $t - 1$ 个单词标注的词性
 - y_t : 表示要评分的标注序列中第 t 个单词标注的词性



- 模型目标

- w_k 为第 k 个特征函数的权重，权重越大表明该特征越重要

$$P(Y|X) = \frac{\exp(\sum_{k=1}^K w_k \sum_{t=1}^n f_k(X, t, y_{t-1}, y_t))}{\sum_{Y' \in \mathbb{Y}} \exp(\sum_{k=1}^K w_k \sum_{t=1}^n f_k(X, t, y'_{t-1}, y'_t))}$$

$$= \frac{1}{Z(X)} \exp \left(\sum_{t=1}^n \sum_{k=1}^K w_k f_k(X, t, y_{t-1}, y_t) \right)$$

$$Z(X) = \sum_{Y' \in \mathbb{Y}} \exp \left(\sum_{t=1}^n \sum_{k=1}^K w_k f_k(X, t, y'_{t-1}, y'_t) \right)$$

线性链CRF中的三类问题

- 概率计算
 - 已知模型线性链CRF，计算观测序列 X 出现的概率 $P(X)$ $P(\text{教授 喜欢 画 画})$
- 模型学习（参数估计）
 - 已知观测序列、标记序列以及所有特征函数，求模型参数（特征函数的权重 w_k ）
- 预测（解码）
 - 已知模型线性链CRF，求观测序列 X 对应的最可能的状态序列 $Y = (y_1, y_2, \dots, y_n)$
 $\operatorname{argmax}_Y P(Y | \text{教授 喜欢 画 画})$

- 特征表示
 - 特征函数集合中的所有特征函数
- 模型参数
 - 特征函数的权重 w_k
- 模型学习（最小化负对数似然）
 - 梯度下降法

$$\mathcal{L} = -\log P(Y|X) = \sum_{X' \in \mathbb{D}} \left(\log Z(X') - \sum_{t=1}^n \sum_{k=1}^K w_k f_k(X', t, y_{t-1}, y_t) \right)$$

- 模型解码
 - 给定句子 X , 预测出最有可能的词性标注序列 Y

$$\begin{aligned}\operatorname{argmax}_Y P(Y|X) &= \operatorname{argmax}_Y \frac{1}{Z(X)} \exp \left(\sum_{t=1}^n \sum_{k=1}^K w_k f_k(X, t, y_{t-1}, y_t) \right) \\ &= \operatorname{argmax}_Y \sum_{t=1}^n \sum_{k=1}^K w_k f_k(X, t, y_{t-1}, y_t)\end{aligned}$$

- 模型解码（维特比算法）
 - $\delta_t(i)$: t 时刻词性为 q_i ($i = 1, 2, \dots, Q$) 的所有可能标注 (y_1, y_2, \dots, y_t) 中的最大打分值

$$\delta_t(i) = \max_{1 \leq j \leq Q} \left(\delta_{t-1}(j) + \sum_{k=1}^K w_k f_k(X, t, y_{t-1}, y_t) \right)$$

$$i = 1, 2, \dots, Q; \quad t = 2, \dots, n$$

线性链CRF VS HMM

- 线性链CRF是判别式模型，HMM是生成式模型
- 线性链CRF的建模能力比HMM更强

HMM

$$P(Y, X) = \prod_{t=1}^n P(y_t | y_{t-1}) P(x_t | y_t)$$

HMM对数形式

$$\log P(Y, X) = \sum_{t=1}^n \log P(y_t | y_{t-1}) + \sum_{t=1}^n \log P(x_t | y_t)$$

线性链CRF

$$\text{score}(Y|X) = \sum_{t=1}^n \sum_{k=1}^K w_k f_k(X, t, y_{t-1}, y_t)$$

可以构造特定的特征函数，使得线性链CRF变成HMM的形式

线性链CRF VS SOFTMAX回归

- 线性链CRF可以看成序列化的Softmax回归，都是判别式模型

线性链CRF

$$P(Y|X) = \frac{\exp\left(\sum_{t=1}^n \sum_{k=1}^K w_k f_k(X, t, y_{t-1}, y_t)\right)}{\sum_{Y' \in \mathbb{Y}} \exp\left(\sum_{t=1}^n \sum_{k=1}^K w_k f_k(X, t, y'_{t-1}, y'_t)\right)}$$

Softmax回归


$$P(c_j|X) = \frac{e^{\omega_j^T v}}{\sum_{k=1}^m e^{\omega_k^T v}}$$

生成式模型 VS 判别式模型




$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)}$$


$P(Y|X)$



Naïve Bayes




Markov models




Directional Models


Generative



Logistic Regression



Linear-chain CRF



CRF

Discriminative

Sequences

Graphs

- 判别式模型，直接建模后验概率，类似于LR
- 通常用线性链CRF建模序列化标注任务
- 模型可以融合各种手工设计的特征
 - 可以引入领域知识 ✓
 - 可解释性强 ✓
 - 可以快速的训练和解码 ✓
 - 维度高 ✗
 - 缺少语义表达能力 ✗



03

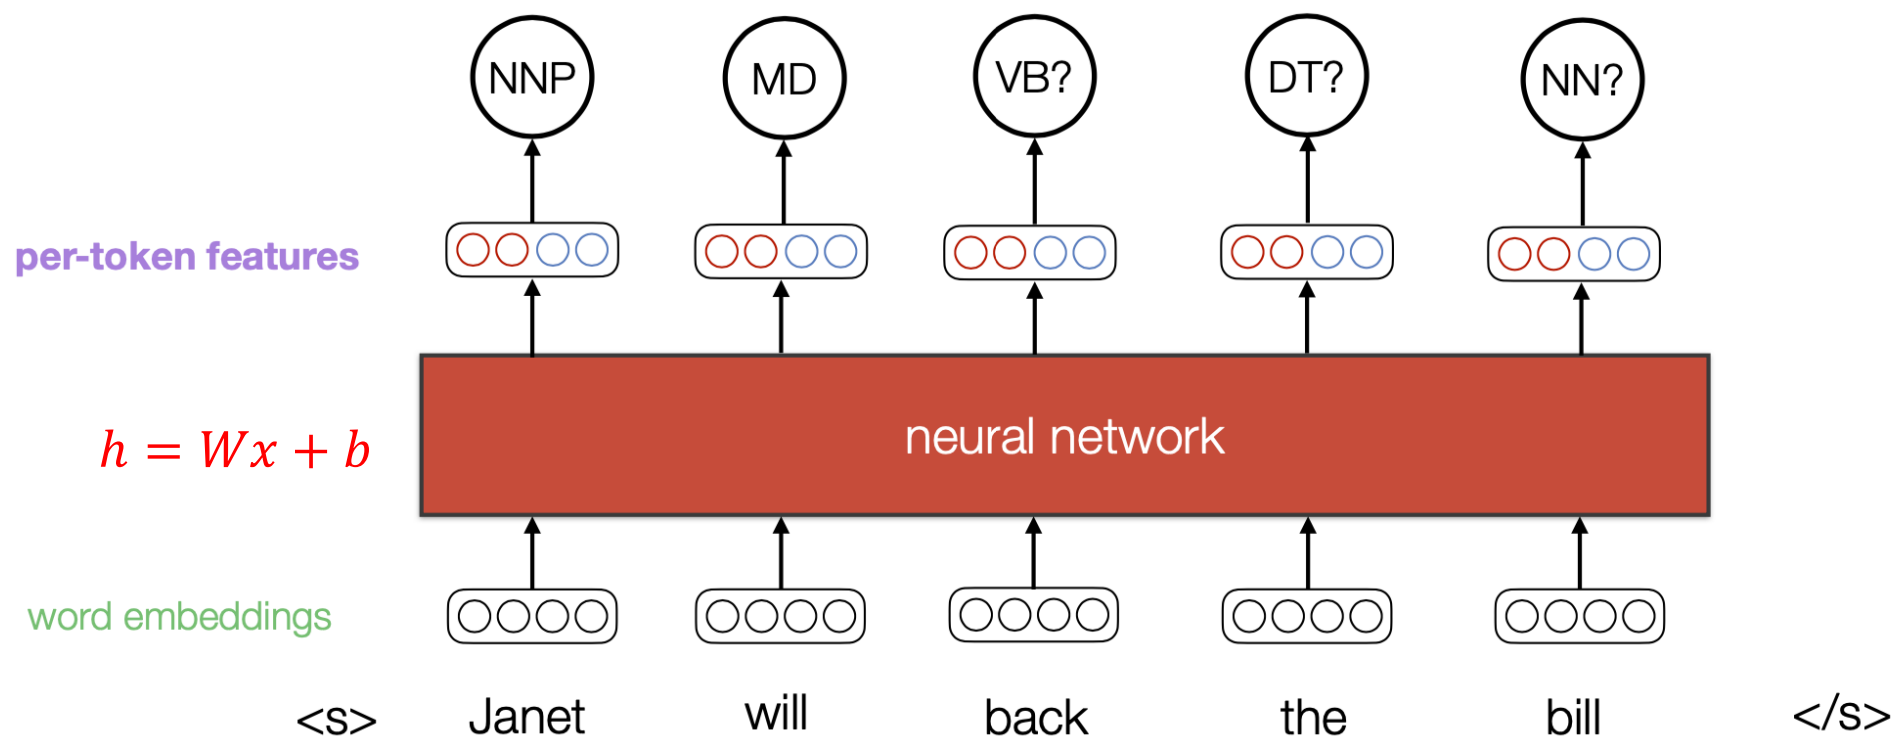


基于深度学习的序列化标注

DEEP LEARNING LEARNING-BASED SEQUENCE LABELING

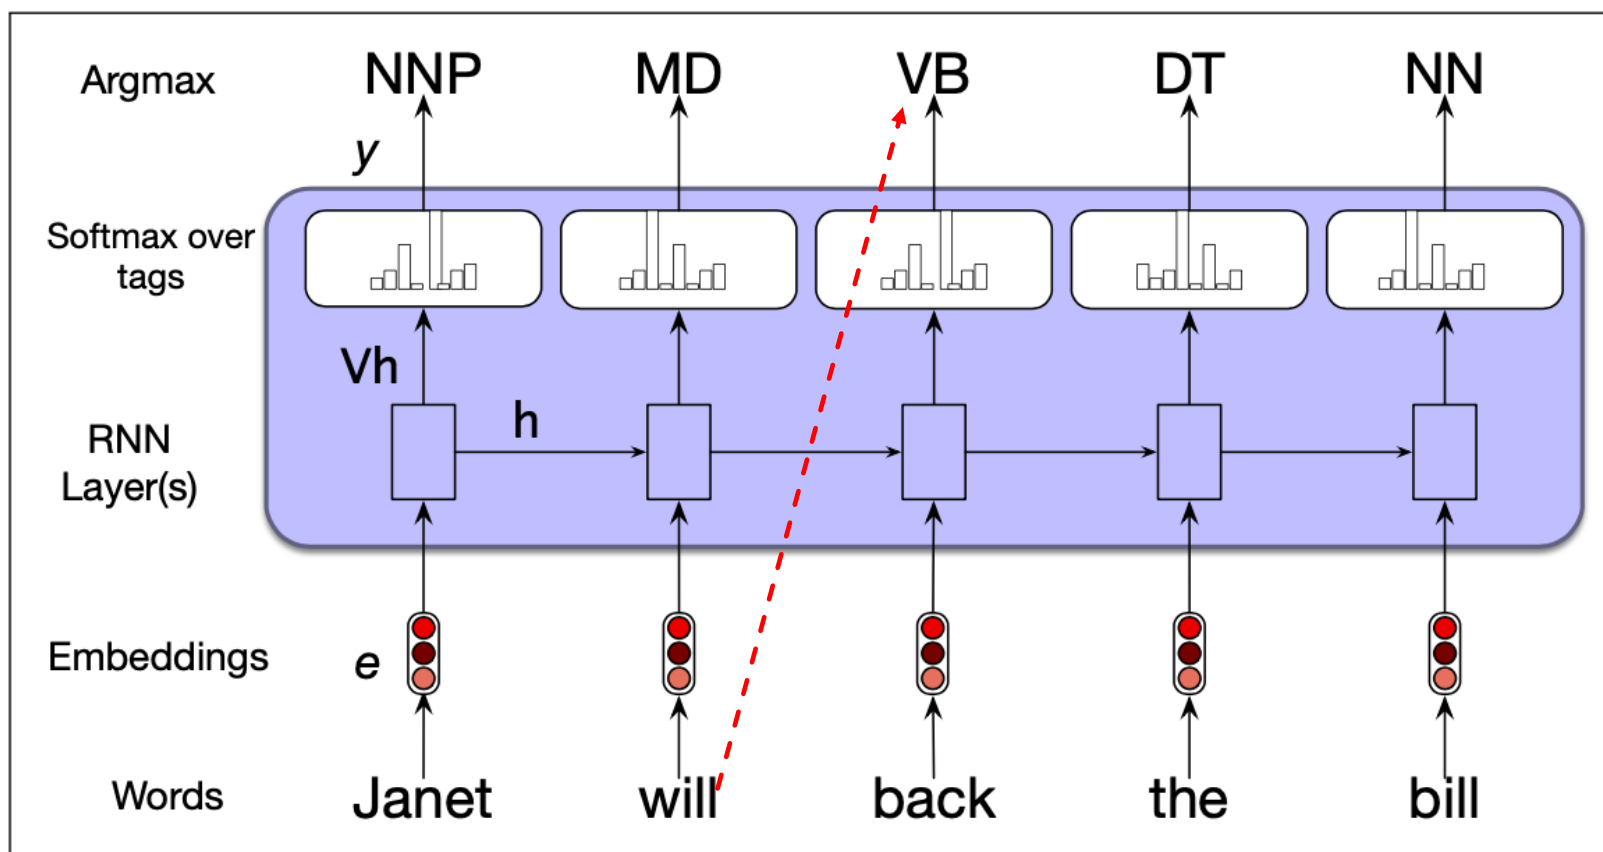
基于深度学习的序列化标注

- 定义：给定一个观测序列作为输入，输出是一个标记序列或状态序列。
- 目标：建立一个神经网络模型，使它能够对观测序列给出对应的标记序列。



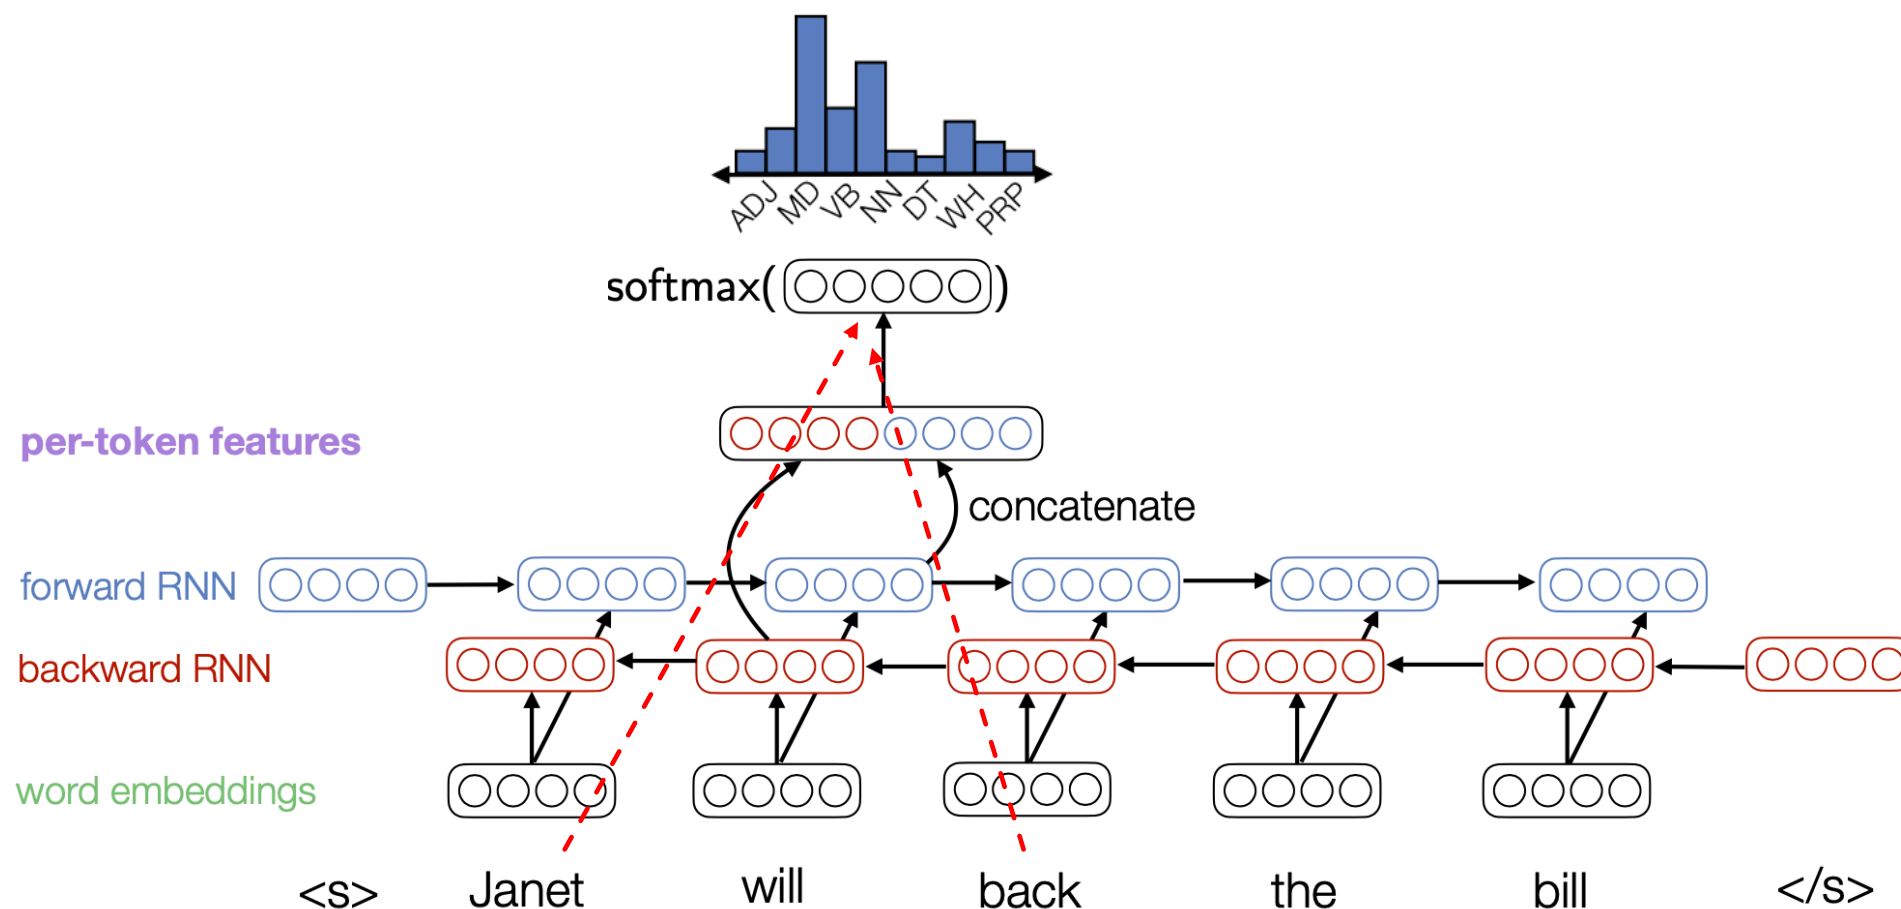
词性标注：RNN

- 利用RNN网络建模序列信息，将序列信息融入词性标注



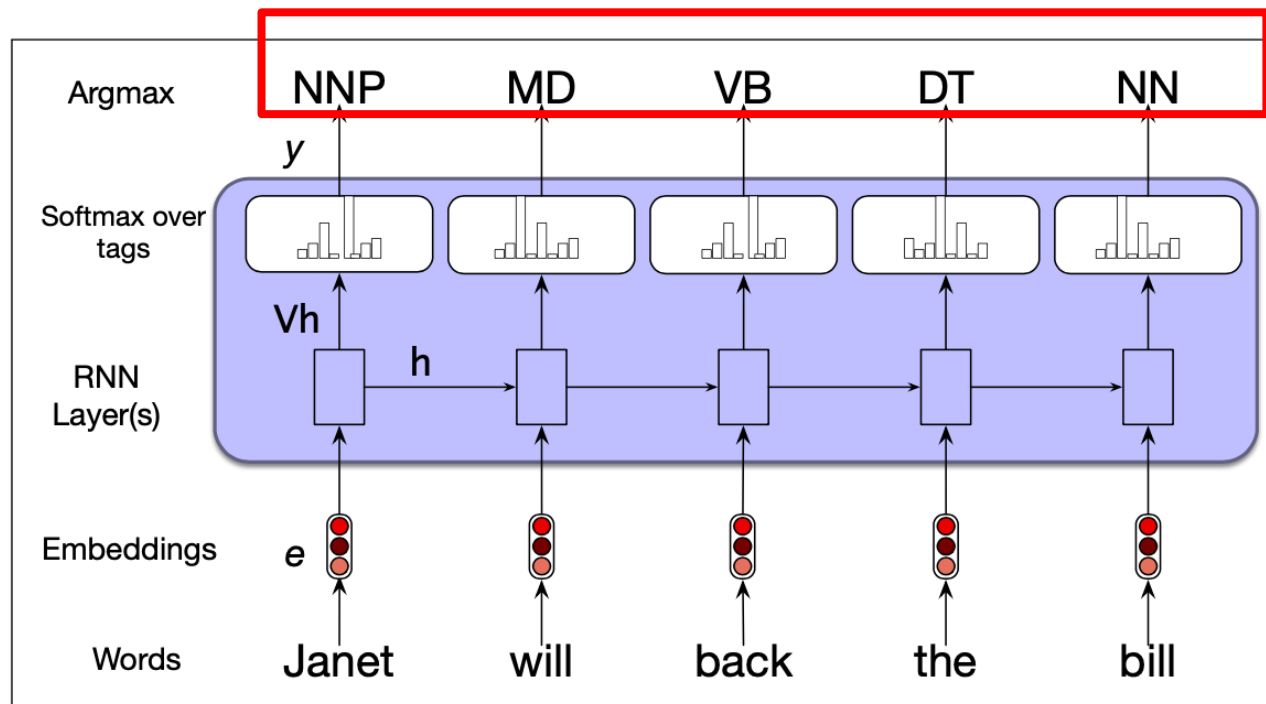
词性标注：BILSTM

- BiLSTM：利用双向LSTM建模上下文信息，将上下文信息同时融入序列化标注



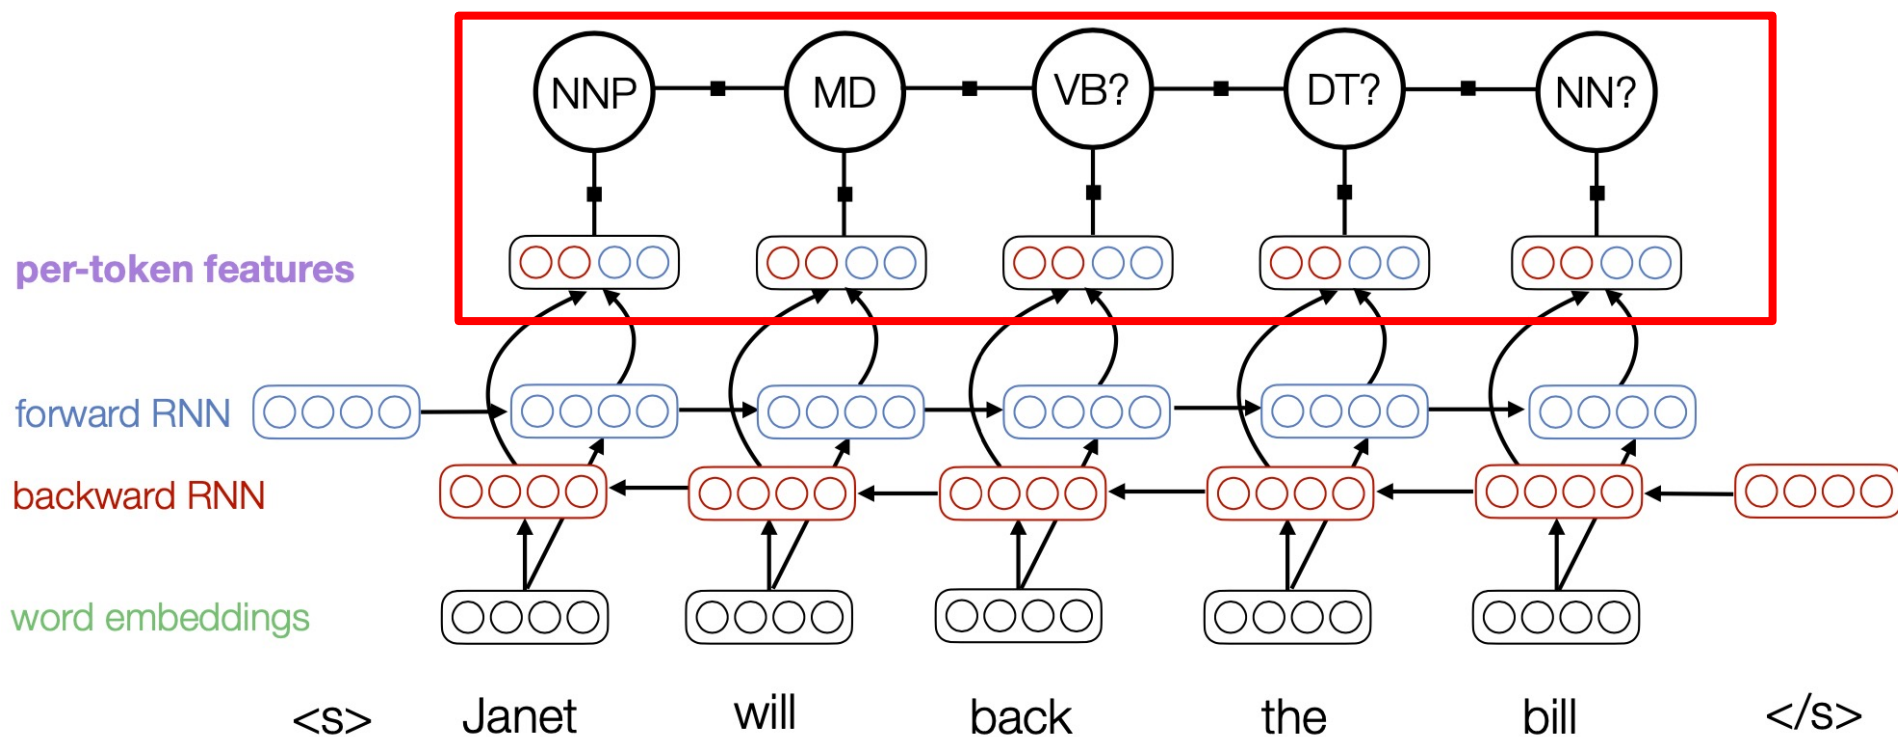
- 输出的词性标签之间相互独立
- 实际上，词性标签之间存在序列相关性。例如，动词后经常会接名词。

预测结果间相互独立，只依赖当前时刻的特征表示



词性标注：BILSTM-CRF

- 在BiLSTM的基础上添加CRF，建模序列依赖性



- CRF

$$P(Y|X) = \frac{\exp(w \cdot F(X, Y))}{\sum_{Y'} \exp(w \cdot F(X, Y'))}$$

- LSTM-CRF的思路：用LSTM来为CRF提供特征
 - $h_i^{y_i}$ 为LSTM在当前时刻的输出值（“输出概率”）
 - P_{y_{i-1}, y_i} 是前一个词性到当前词性的跳转值（“跳转概率”）

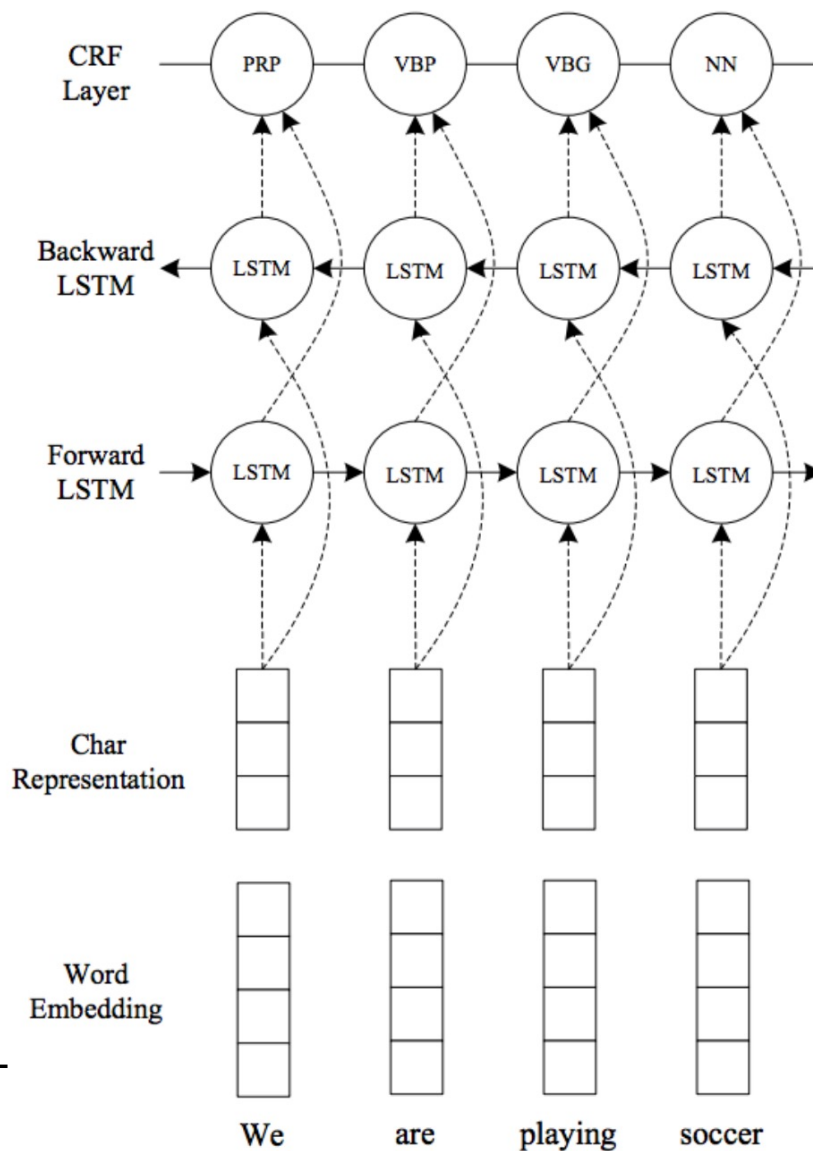
$$w \cdot F(X, Y) = \sum_{i=1}^n (h_i^{y_i} + P_{y_{i-1}, y_i})$$

- 直观理解
 - LSTM的输出值 $h_i^{y_i}$ 越大，当前时刻的词性越有可能是 y_i
 - 跳转值 P_{y_{i-1}, y_i} 越大，当前时刻的词性越有可能是 y_i
- $h_i^{y_i}$ 通过LSTM的网络参数得到
- P_{y_{i-1}, y_i} ：跳转矩阵 P 也是一个可学习的参数
- LSTM-CRF通过跳转矩阵 P 建模词性标签之间的依赖关系

词性标注：LSTM-CNN-CRF

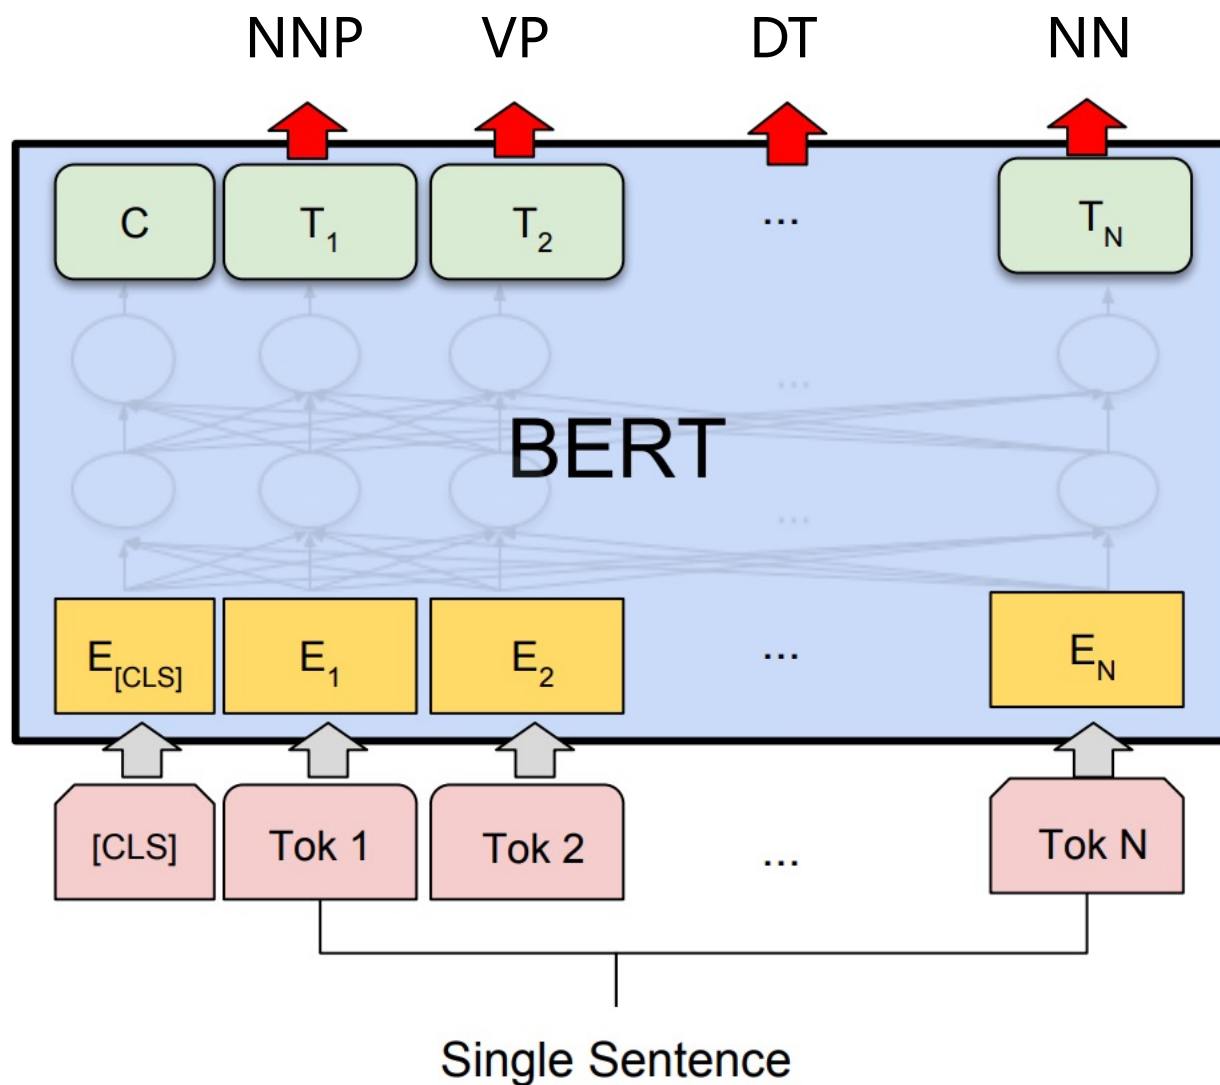


- 利用CNN来建模单词内的字符串信息
- 一些特定的字符串（如英语中各种与词性相关的前缀、后缀）对词性标注是有帮助的



词性标注：预训练模型

- 预训练模型中有丰富的语义信息，可以帮助更准确地理解上下文信息
- 从而生成更准确的词性标注序列



序列化标注能解其他词法分析任务吗？

- 中文分词
 - 分词是指根据某个分词规范，把一个“字”串划分成“词”串。
 - 样例：“独立/自主/和/平等/独立/的/原则”
- 命名实体识别 (NER)
 - 识别出一句话中的所有命名实体 (人名、地名、机构名等)

人名 机构名 地名
└──┬──┘ └──┬──┘ └──┬──┘
小明 在 南京大学 的 方肇周体育馆 看了一场比赛

- 输入句子 $X = (x_1, x_2, \dots, x_n)$
- 标签序列 $Y = (y_1, y_2, \dots, y_n)$
 - $y_i \in \{B, I, O\}$
 - B用来表示一个片段的开始
 - I用来表示一个片段的内部或结束
 - O用来表示其它字段 (可选, 根据问题决定)

序列化标注：中文分词

- 标签集合为{B, I}
 - B表示一个词的开始
 - I表示一个的内部或结束

独 立 自 主 和 平 等 独 立 的 原 则




B I B I B B I B I B B I



独 立/ 自 主/ 和/ 平 等/ 独 立/ 的/ 原 则

- 标签集合为 $\{B, I\} \times \{PER, LOC, ORG\} + \{O\}$
 - B和I用来表示命名实体的开始位置、中间或结束位置
 - PER, LOC, ORG表示当前命名实体为人民、地名、或机构名
 - O表示非命名实体片段



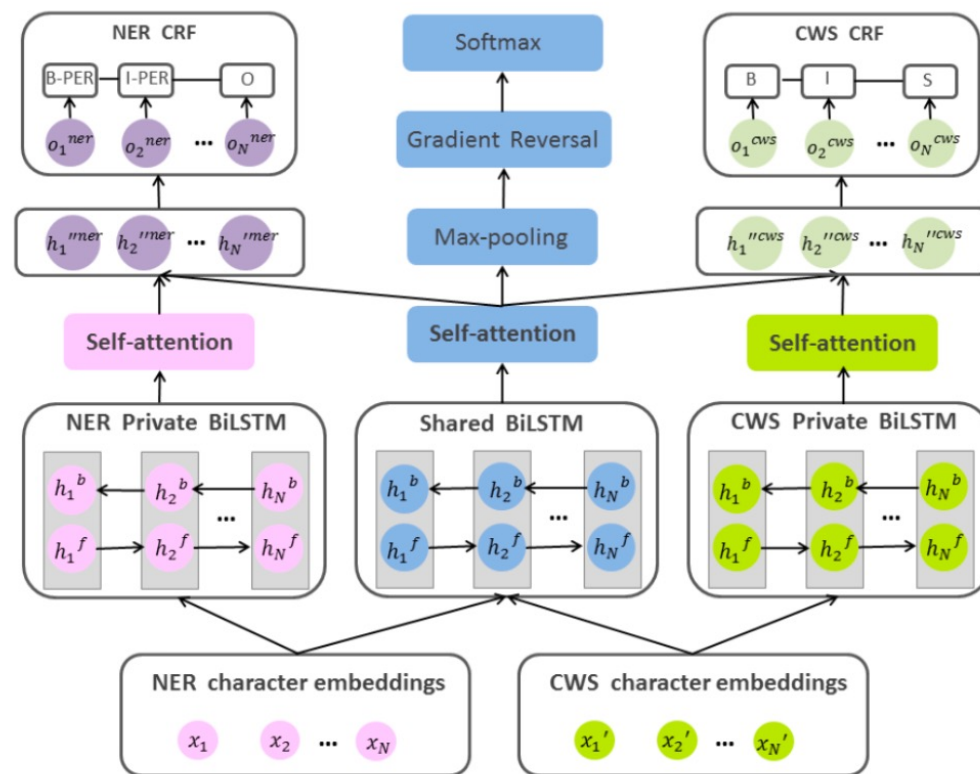
- 标签集合为{B, I, E, O, S}
 - B表示一个片段的开始
 - I表示一个片段的内部
 - E表示一个片段的结束
 - S表示由单个词组成的片段
 - O表示其他词

序列化标注任务之间的相关性

- 中文分词是词性标注和命名实体识别的基础
- 词性信息能够帮助命名实体识别
 - 例如，名词可能是命名实体
- 命名实体识别也能帮助词性标注
 - 例如，命名实体很可能是名词词性
-

- 将多个任务放在多任务学习框架中进行联合学习
- 为什么需要多任务学习？
 - 数据不足
 - 任务之间有关联，可以相关补充信息
- 如何设计多任务学习框架？
 - 和特定的任务有关系

- 基于共享-私有结构的多任务学习框架
 - 共享结构用于学习两个任务共享、能够相互迁移的信息
 - 私有结构用于学习任务特定的信息





南京大學
NANJING UNIVERSITY

Thank you !
Q&A

